

Снижение размерности латентного пространства в задачах управления

Александр Михайлович Астахов

Научный руководитель: д. ф.-м. н. В. В. Стрижов

Кафедра интеллектуальных систем ФПМИ МФТИ

Направление: 01.03.02 Прикладная математика и информатика

Москва — 2026

Снижение размерности латентного пространства в задачах управления

Цель исследования

Снижение размерности латентного пространства динамической системы и построение в редуцированном пространстве оператора связности, описывающего направленные взаимодействия между датчиками, для прогнозирования состояния системы.

Задача

Сжать избыточные координаты вложения Такенса до компактного латентного представления и построить в нём оператор связности, не ограниченный симметричным классом.

Предложенный метод

Метод MoE-GA: автоэнкодер над координатами вложения Такенса для снижения размерности и смесь экспертов с асимметричными матрицами внимания для построения оператора связности. Модель прогноза: $\hat{g} = D \circ G_{\theta}^k \circ \mathcal{E}_{\phi}$.

Формальная постановка задачи

Фазовое пространство $\mathcal{M} = L^2(\Omega)$, $\Omega \subset \mathbb{R}^n$. Компактный аттрактор $\mathcal{A} \subset \mathcal{M}$, $d_{\mathcal{A}} < \infty$. Наблюдения $s(t) = (h_1(u(t)), \dots, h_C(u(t))) \in \mathbb{R}^C$. Класс систем: нелинейные LPV, $A(u) \in \{A_1, \dots, A_K\}$.

Теорема о вложении (Takens, 1981; Sauer et al., 1991)

При $Cm \geq 2d_{\mathcal{A}} + 1$: $\Phi(t) = (s_i(t - j\tau))_{\substack{i=1,\dots,C \\ j=0,\dots,m-1}} \in \mathbb{R}^{C \times m}$ — вложение
 $\mathcal{A} \hookrightarrow \mathbb{R}^{C \times m}$.

Модель прогноза — суперпозиция $\hat{g} = D \circ G_{\theta}^k \circ \mathcal{E}_{\phi}$:

$\mathcal{E}_{\phi} : \mathbb{R}^C \rightarrow \mathbb{R}^{C \times L}$ — энкодер (вложение + сжатие + трансформер),

$G_{\theta} : \mathbb{R}^{C \times L} \rightarrow \mathbb{R}^{C \times L}$ — шаг динамики в латенте (graph attention),

$D : \mathbb{R}^{C \times L} \rightarrow \mathbb{R}^C$ — линейный декодер.

Ограничение симметричных моделей

Стандартные модели связности (корреляция Пирсона, ядерные графы) дают $\hat{A} \in \mathcal{H}_{\text{sym}}$ по построению. Ортогональное разложение $\mathbb{R}^{C \times C} = \mathcal{H}_{\text{sym}} \oplus \mathcal{H}_{\text{asym}}$:

$$A = A_{\text{sym}} + A_{\text{asym}}, \quad \|A\|_F^2 = \|A_{\text{sym}}\|_F^2 + \|A_{\text{asym}}\|_F^2.$$

Нижняя граница ошибки (доказано в работе)

Для любых $A \in \mathbb{R}^{C \times C}$ и $M \in \mathcal{H}_{\text{sym}}$:

$$\|A - M\|_F^2 \geq \|A_{\text{asym}}\|_F^2 = \frac{1}{4} \|A - A^\top\|_F^2.$$

Неустраняемая ошибка любой симметричной модели: $\mathbb{E} \|A_{\text{asym}}(u)\|_F^2$.

Следствие: оператор $\hat{A}_\theta(z)$ не должен быть ограничен $\mathcal{H}_{\text{sym}}$. Это мотивирует переход к асимметричной параметризации.

Энкодер $\mathcal{E}_\phi$: от наблюдений к латенту

Энкодер $\mathcal{E}_\phi = T_\phi \circ E_\phi \circ \Phi$ — суперпозиция:

$\Phi : \mathbb{R}^C \rightarrow \mathbb{R}^{C \times m}$ — вложение по задержкам (τ, m) ,

$E_\phi : \mathbb{R}^{C \times m} \rightarrow \mathbb{R}^{C \times L}$ — автоэнкодер (маскир. + простр. трансформер),

$T_\phi : \mathbb{R}^{C \times L} \rightarrow \mathbb{R}^{C \times L}$ — временной трансформер по каждому датчику.

Размерность латента $L = \text{round}(m \times 2/3)$. Реконструкционный лосс обеспечивает информативность при $L < m$:

$$\mathcal{L}_{\text{rec}} = \frac{1}{|\mathcal{T}| C m} \sum_t \|\Phi(t) - D_\phi(z(t))\|_{\mathbb{F}}^2.$$

Выход энкодера — $z(t) \in \mathbb{R}^{C \times L}$, подготовленный для шага пространственной динамики G_θ .

Оператор связности: смесь экспертов

Для каждой моды $k = 1, \dots, K$ — проекции $W_k^Q, W_k^K \in \mathbb{R}^{L \times d}$, $d = L$:

$$A_k(z) = \frac{(zW_k^Q)(zW_k^K)^\top}{\sqrt{d}}, \quad \text{rank}(A_k) \leq L.$$

Маршрутизатор Гумбеля жёстко выбирает одного эксперта: $\hat{A}_\theta(z) = \text{SN}(A_{\hat{k}}(z))$,
 $\hat{k} = \arg \max_k R_\psi(\bar{z})_k$.

Шаг динамики — residual graph attention:

$$G_\theta(z) = z + \alpha [\hat{A}_\theta(z) V(z) + f_\theta(z)], \quad \alpha = \sigma(\alpha_0).$$

MoE-GA: $f_\theta \equiv 0$. MoE-GA Full: $f_\theta = W_2 \text{GELU}(W_1 \text{LN}(z))$.

Декодер $D: \mathbb{R}^{C \times L} \rightarrow \mathbb{R}^C$ — линейная проекция.

Иерархия семейств (доказано в работе)

$W_k^Q = W_k^K \Rightarrow \hat{A}_\theta \in \mathcal{H}_{\text{sym}}$ — симметричные модели являются частным случаем.
 $W_k^Q \neq W_k^K, d \geq C \Rightarrow \mathcal{F}_\Theta^{\text{sym}} \subsetneq \mathcal{F}_\Theta$. В реализации $d = L < C$ — низкоранговое приближение.

Совместный функционал обучения:

$$\mathcal{L} = \mathcal{L}_{\text{pred}} + \lambda_1 \mathcal{L}_{\text{ind}} + \lambda_2 \mathcal{L}_{\text{rec}} + \lambda_3 \mathcal{L}_{\text{reg}} + \lambda_4 \mathcal{L}_{\text{phase}}, \quad \theta^* = \arg \min_{\theta} \mathcal{L},$$

$\mathcal{L}_{\text{pred}}$ — rollout на H шагов через $D \circ G_\theta^k$

$\mathcal{L}_{\text{ind}}$ — внутриоконный одношаговый прогноз

$\mathcal{L}_{\text{rec}}$ — реконструкция координат вложения


$\mathcal{L}_{\text{reg}}$ — баланс K экспертов, $\text{KL}(\bar{w} \parallel \text{Uniform})$

$\mathcal{L}_{\text{phase}}$ — фазовая голова (только синтетика)

Эксперимент: drift-ring ($C=16$, бинарные режимы)

Кольцо из $C=16$ датчиков, циркулянтный оператор переключается каждые 500 шагов. Асимметрия $\approx 1,41$. $T=3000$, $L=3$, $K=6$, $H=4$, 5 сидов.


Модель	MSE	A_{asym}	Ул.
Корреляция	$0,229 \pm .035$	≈ 0	—
MoE-GA	$0,211 \pm .023$	0,467	7,9%
MoE-GA Full	$0,204 \pm .024$	0,255	11,1%



MoE-GA Full снижает MSE на 11,1% и восстанавливает направленность.

Восстановленные матрицы связности: drift-ring

Learned coupling matrices vs ground truth (C=16, latent_dim=2, m=4)




Средние $\hat{A}$ по двум режимам и истинные T_+ , T_- . Корреляция: $a=0$, направление не различается. MoE-GA: $a=1,58 \approx 1,41$; маршрутизатор активирует 2 из 6 мод. MoE-GA Full: $a=0,09$, реакционный член перехватывает часть асимметрии, но инверсия направления обнаруживается.

Эксперимент: ЭЭГ моторного воображения ($C=64$)


PhysioNet EEGBCI, $C=64$, 160 Гц,
 $T=30\,000$. Автоматически: $\tau=9$, $m=5$,
 $L=3$, $K=4$ (Марченко–Пастур). $H=8$, 3
сида.

Модель	MSE	A_{asym}	Ул.
Корреляция	$0,472 \pm .007$	≈ 0	—
MoE-GA	$0,450 \pm .006$	0,016	4,7%
MoE-GA Full	$0,440 \pm .007$	0,085	6,8%



Прирост скромнее: направленная составляющая в ЭЭГ выражена слабее.

Восстановленные матрицы связности: ЭЭГ



Усреднённые матрицы $\hat{A}$ ($C=64$): Corr, MoE-GA, MoE-GA Full. Блочная структура соответствует анатомическим группам электродов — моторная кора (Cz, C3, C4), лобные и затылочные кластеры. Маршрутизатор распределяет $K=4$ режима, что согласуется с $K_{MP}=4$.

Выносятся на защиту

1. **Доказано**, что ошибка аппроксимации оператора связности любой симметричной моделью ограничена снизу величиной $\mathbb{E} \|A_{\text{asym}}(u)\|_F^2$, не зависящей от объёма данных и числа параметров.
2. **Предложен** метод прогнозирования $\hat{g} = D \circ G_\theta^k \circ \mathcal{E}_\phi$ с оператором связности в редуцированном пространстве $L = \text{round}(m \times 2/3)$; симметричные модели — частный случай: $\mathcal{F}_\Theta^{\text{sym}} \subsetneq \mathcal{F}_\Theta$.
3. **Показано** экспериментально, что MoE-GA снижает MSE на 11,1% ($C=16$) и 6,8% ($C=64$) и восстанавливает направленную структуру оператора.