

Министерство образования и науки Российской Федерации
Московский физико-технический институт (национальный
исследовательский университет)

Физтех-школа прикладной математики и информатики
Кафедра интеллектуальных систем

Выпускная квалификационная работа бакалавра по направлению 010302
«Прикладные математика и физика»

Снижение размерности латентного пространства в задачах управления

Студент Б05-251л группы
Астахов А. М.

Научный руководитель
д. ф.-м. н. Стрижов В.В.

Долгопрудный
2026

Содержание

1. Аннотация	1
2. Введение	2
3. Формальная постановка задачи	4
3.1. Пространство состояний и наблюдения	4
3.2. Задержечное представление состояния	4
3.3. Локально-линейное представление и оператор связи	5
3.4. Симметричное и антисимметричное разложение	5
3.5. Симметричные модели и принципиальное ограничение	5
3.6. Задачи	6
4. Формальное описание модели	7
4.1. VAE-энкодер над координатами Такенса	8
4.2. Временной трансформер в латенте	8
4.3. Граф датчиков и residual graph attention	8
4.4. Асимметричная матрица внимания	9
4.5. Реакционный член	10
4.6. Декодер прогноза	10
5. Оптимизационная задача	11
5.1. Порождающая модель и вариационный нижний предел	11
5.2. Прогнозный лосс	12
5.3. Регуляризатор маршрутизации	12
5.4. Совокупная задача оптимизации	12
6. Вычислительный эксперимент	14
6.1. Сценарии	14
6.2. Синтетический датасет: кольцо с дрейфующим ядром	14
6.3. Реальный датасет: EEG моторного воображения	14
6.4. Сравнимые модели	14
6.5. Параметры обучения	15
6.6. Метрики	15
6.7. Результаты на синтетике	15
6.8. Результаты на EEG	16

6.9. Связь результатов с основным тезисом	17
7. Заключение	19

Глава 1

Аннотация

Работа посвящена задаче снижения размерности в распределённых динамических системах для построения предсказательной модели, пригодной к последующему использованию в контурах управления. Стандартные графовые подходы опираются на симметричное представление парных связей между датчиками: попарная корреляция Пирсона, ядерные графы $w_{ij} = \kappa(\|\xi_i - \xi_j\|)$. Все они по построению выдают коэффициент связи, удовлетворяющий $\hat{A}_{ij} = \hat{A}_{ji}$, и потому не способны представить направленный перенос информации.

В работе сформулирован и подтверждён тезис: асимметричная матрица внимания, построенная на основе геометрии фазового пространства, лучше подходит для предсказания и восстановления скрытых зависимостей, чем симметричная корреляционная матрица. Предложена параметризация оператора связи через банкованное multi-head attention с несвязанными проекциями запросов и ключей; при связанных проекциях семейство строго вырождается в симметричный класс, покрывающий корреляцию и tied-attention. Динамика латентного представления реализована как residual graph-attention блок с реакционным MLP редукция состояния выполнена через вариационный автоэнкодер над задержечными координатами Такенса.

На контролируемой синтетической системе с заведомо асимметричным оператором переноса предложенная модель снижает ошибку прогноза на 22 % относительно корреляционного baseline, восстанавливает антисимметричную составляющую истинного оператора и корректно разделяет режимы. На реальных данных EEG моторного воображения наблюдается аналогичный, хотя и менее выраженный, прирост по ошибке прогноза.

Глава 2

Введение

Прогноз и управление распределёнными динамическими системами сталкиваются с двумя трудностями. Во-первых, истинное состояние системы — поле или вектор большой размерности, наблюдаемый лишь через конечный набор датчиков. Во-вторых, связи между датчиками, как правило, не статичны: фаза, режим, локальные условия определяют, кто на кого и насколько влияет в данный момент. Эффективная редуцированная модель должна одновременно учитывать оба обстоятельства.

Классический путь снижения размерности в этой задаче — построение графа связей между датчиками и обучение динамики на этом графе. Простейшая и исторически популярная конструкция использует попарную корреляцию Пирсона: $\hat{\Sigma}_{ij} = \text{corr}(s_i, s_j)$. Эта матрица симметрична по построению. Аналогично симметричны ядерные графы вида $\kappa(\|\xi_i - \xi_j\|)$, а также классическое self-attention [13] при условии $W^Q = W^K$, когда оператор внимания сводится к матрице Грама. Объединяя эти примеры, получаем обширный класс симметричных моделей связности, для которого $\hat{A}_{ij} = \hat{A}_{ji}$ выполнено тождественно.

Между тем, во многих практически значимых системах связь между датчиками существенно направлена. Адвекционные процессы переносят информацию по потоку (атмосфера, реки, трафик; типичный пример — графовое прогнозирование дорожного трафика через диффузионную рекуррентную сеть [4]); причинно-следственные сети нейрофизиологических и климатических сигналов организованы иерархически и для них формализована Granger-причинность [2] и сходящееся кросс-отображение [10]; финансовые рынки демонстрируют lead-lag-эффекты между регионами. Антисимметричная часть истинного оператора связи $A(u) = A_{\text{sym}}(u) + A_{\text{asym}}(u)$ несёт информацию о направленности; при симметризации эта часть полностью теряется.

Этим мотивирована геометрическая постановка задачи: представить динамику как процесс на графе, в котором сами рёбра ориентированы и взвешены неравными скалярами $A_{ij} \neq A_{ji}$. Конструктивная реализация такого процесса — обучаемое распространение информации по графу через механизм внимания с независимыми проекциями запросов и ключей [13, 14], при итеративном применении с residual-связью.

Низкоразмерное представление состояния необходимо по двум причинам. Первая

— содержательная: наблюдаемая динамика, согласно гипотезе существования инерциального многообразия [12], порождается конечномерным латентным процессом, и работа в его координатах геометрически корректна. Вторая — вычислительная: задержечные координаты Такенса [11, 8] дают избыточное, шумное представление, и вариационный автоэнкодер [3] снимает обе проблемы — одновременно сжимает координаты до латента низкой размерности и регуляризует их через KL-член, выбирая среди эквивалентных параметризаций гладкую, согласованную с гауссовским приором. Минимизация ELBO в этой постановке соответствует поиску устойчивого порождающего представления скрытой динамики.

Глава 3

Формальная постановка задачи

3.1 Пространство состояний и наблюдения

Рассматривается распределённая динамическая система с фазовым пространством $\mathcal{M}$ (в общем случае бесконечномерным). Эволюция задана однопараметрическим оператором $\varphi : \mathbb{R}_{\geq 0} \times \mathcal{M} \rightarrow \mathcal{M}$, не предполагаемым линейным.

Предположение 1 (Конечномерный аттрактор). Существует компактное φ -инвариантное множество $\mathcal{A} \subset \mathcal{M}$ конечной бокс-размерности $d_{\mathcal{A}} < \infty$, на которое все траектории сходятся. Элементы $\mathcal{A}$ обозначаются u и считаются скрытым состоянием системы.

Наблюдение производится в фиксированных пространственных точках $\xi_1, \dots, \xi_C \in \Omega$ через гладкие функции $h_i : \mathcal{M} \rightarrow \mathbb{R}$. Вектор наблюдений

$$s(t) = (h_1(u(t)), \dots, h_C(u(t))) \in \mathbb{R}^C, \quad u(t) \in \mathcal{A}. \quad (1)$$

Доступные данные — дискретная траектория $\mathcal{D} = \{s(t_n)\}_{n=0}^N$ с равномерным шагом $t_n = n\Delta t$.

3.2 Задержечное представление состояния

Скрытое $u(t)$ напрямую не наблюдается. Теорема Такенса о вложении по задержкам [11] и её обобщение для многосенсорных и фрактальных аттракторов [8] утверждают, что для гладких h_i и подходящих $\tau > 0$, $m \in \mathbb{N}$ отображение

$$\Phi(t) = (s_i(t - j\tau))_{i=1, \dots, C; j=0, \dots, m-1} \in \mathbb{R}^{C \times m} \quad (2)$$

при $Cm \geq 2d_{\mathcal{A}} + 1$ является погружением $\mathcal{A}$ в евклидово пространство. Это позволяет заменить ненаблюдаемое состояние u на наблюдаемые координаты $\Phi(u)$, согласованные с геометрией аттрактора.

3.3 Локально-линейное представление и оператор связи

Утверждение 1 (Локальная линейаризация). При C^1 -гладкости $\varphi_{\Delta t}$ и h существует отображение $A : \mathcal{A} \rightarrow \mathbb{R}^{C \times C}$ такое, что

$$s(t + \Delta t) = A(u(t)) s(t) + \eta(t), \quad \mathbb{E}[\eta(t) \mid \mathcal{F}_t] = 0, \quad (3)$$

с точностью до $o(\Delta t)$. Матрица $A(u)$ называется оператором связи между датчиками.

3.4 Симметричное и антисимметричное разложение

Введём скалярное произведение Фробениуса $\langle P, Q \rangle_F = \text{tr}(P^\top Q)$ и подпространства $\mathcal{H}_{\text{sym}} = \{M : M^\top = M\}$ и $\mathcal{H}_{\text{asym}} = \{M : M^\top = -M\}$.

Лемма 1 (Ортогональное разложение). Пространство $\mathbb{R}^{C \times C}$ есть ортогональная прямая сумма $\mathcal{H}_{\text{sym}} \oplus \mathcal{H}_{\text{asym}}$ с размерностями $\dim \mathcal{H}_{\text{sym}} = C(C + 1)/2$ и $\dim \mathcal{H}_{\text{asym}} = C(C - 1)/2$. Любая $A \in \mathbb{R}^{C \times C}$ единственным образом раскладывается

$$A = A_{\text{sym}} + A_{\text{asym}}, \quad A_{\text{sym}} = \frac{1}{2}(A + A^\top), \quad A_{\text{asym}} = \frac{1}{2}(A - A^\top), \quad (4)$$

причём $\|A\|_F^2 = \|A_{\text{sym}}\|_F^2 + \|A_{\text{asym}}\|_F^2$.

Доказательство. При $P^\top = P$, $Q^\top = -Q$ имеем $\text{tr}(P^\top Q) = \text{tr}(PQ) = -\text{tr}(PQ) = 0$. Дальнейшее — стандартная проверка. $\square$

3.5 Симметричные модели и принципиальное ограничение

Определение 1 (Симметричный класс). Семейство параметризованных моделей $\hat{A}_\theta(z)$ называется симметричным, если $\hat{A}_\theta(z) \in \mathcal{H}_{\text{sym}}$ для всех θ и z .

Корреляционная модель $\hat{A} = \gamma \hat{\Sigma}$ принадлежит симметричному классу. К нему же относятся ядерные графы и self-attention с $W^Q = W^K$: произведение $zW^Q(zW^Q)^\top$ есть матрица Грама, симметричная по построению.

Утверждение 2 (Нижняя граница ошибки симметричной аппроксимации). Для любой $A \in \mathbb{R}^{C \times C}$ и любой $M \in \mathcal{H}_{\text{sym}}$

$$\|A - M\|_F^2 \geq \|A_{\text{asym}}\|_F^2 = \frac{1}{4}\|A - A^\top\|_F^2, \quad (5)$$

с равенством при $M = A_{\text{sym}}$.

Доказательство. $A - M = (A_{\text{sym}} - M) + A_{\text{asym}}$ — ортогональная сумма по лемме 1; теорема Пифагора даёт неравенство. $\square$

Следствие 1 (Принципиальная потеря). *Если истинный оператор $A(u)$ имеет ненулевую антисимметричную часть $A_{\text{asym}}(u)$, то любая симметричная модель имеет неустранимую среднюю ошибку аппроксимации, равную $\mathbb{E} \|A_{\text{asym}}(u)\|_F^2$. Эта ошибка не уменьшается ни увеличением числа параметров, ни увеличением объёма данных.*

Утверждение 1 формализует основной тезис работы: для систем с направленной составляющей динамики требуется выйти за пределы симметричного класса.

3.6 Задачи

По траекториям $\mathcal{D}$ требуется:

1. построить низкоразмерное представление $z(t) \in \mathbb{R}^{C \times L}$ скрытого состояния системы, согласованное с теоремой Такенса;
2. построить параметризованное отображение $\hat{A}_\theta : z \mapsto \mathbb{R}^{C \times C}$, не ограниченное симметричным подпространством $\mathcal{H}_{\text{sym}}$;
3. обучить модель прогноза $s(t + k\Delta t)$ на горизонте H через итеративную динамику в латенте.

Глава 4

Формальное описание модели

Архитектура состоит из четырёх блоков: вариационного автоэнкодера [3] над задержечными векторами Такенса [11], временного трансформера [13] в латенте, пространственного оператора с асимметричной матрицей внимания и реакционным членом, а также покомпонентного декодера. Общая схема показана на рис. 1.




Рис. 1. Схема модели. Состояние сжимается до латента $z(t)$, по которому параллельно вычисляются веса режимов и банк ядер; их свёртка даёт асимметричный оператор $\hat{A}(z)$, по которому далее выполняется один residual-шаг graph attention с реакционным членом, после чего декодер восстанавливает наблюдения.

4.1 VAE-энкодер над координатами Такенса

Для каждого датчика i строится задержечный вектор $\Phi_i(t) = (s_i(t), s_i(t-\tau), \dots, s_i(t-(m-1)\tau)) \in \mathbb{R}^m$. Параметры τ и m выбираются глобально по всем датчикам: τ — первый локальный минимум усреднённой по сенсорам взаимной информации, m — наименьшее значение, при котором средняя по датчикам доля ложных ближайших соседей опускается ниже порога.

Покомпонентный (по датчикам) каузальный трансформерный энкодер $E_{\theta_{\text{enc}}}$ [13] переводит $\Phi_i(t)$ в распределение [3]

$$q_\phi(z_i | \Phi_i) = \mathcal{N}(\mu_\phi(\Phi_i), \text{diag } \sigma_\phi^2(\Phi_i)), \quad (6)$$

где $\mu_\phi, \sigma_\phi^2 : \mathbb{R}^m \rightarrow \mathbb{R}^L$ — параметрические функции. Во время обучения используется репараметризация $z = \mu + \sigma \odot \varepsilon$, $\varepsilon \sim \mathcal{N}(0, I)$; во время вывода — среднее $z_i(t) = \mu_\phi(\Phi_i(t))$. Декодер автоэнкодера $D_\phi : \mathbb{R}^L \rightarrow \mathbb{R}^m$ восстанавливает исходный задержечный вектор Φ_i . Размерность латента $L = m$ (без дополнительного сжатия в координатной оси); KL-член обеспечивает гладкость и шумоподавление.

4.2 Временной трансформер в латенте

Латентная траектория $z(t) \in \mathbb{R}^{C \times L}$ дополнительно обрабатывается каузальным трансформером, действующим по временной оси независимо для каждого датчика. Это аккумулирует временной контекст в латенте без смещения сенсоров и поднимает качество оценки $z(t)$ в окрестности границы окна, где VAE-энкодер видит короткий контекст.

4.3 Граф датчиков и residual graph attention

Пусть $\mathcal{G} = (V, E)$ — полный направленный граф на C вершинах, где каждый узел i соответствует датчику ξ_i . Ребро (i, j) взвешено скаляром $A_{ij}(z) \in \mathbb{R}$, в общем случае не равным $A_{ji}(z)$. Содержательно $A(z)$ есть обучаемая матрица попарных сходств между датчиками в текущем латентном состоянии [13, 14]; от классического self-attention отличается тем, что проекции запросов и ключей несвязаны (см. раздел 4.4), а softmax-нормировка по строкам заменена мягким контролем спектрального радиуса.

Обновление латента — residual-шаг graph attention с обучаемой скалярной величиной $\alpha = \sigma(\alpha_0) \in (0, 1)$:

$$z_{k+1} = z_k + \alpha [\hat{A}(z_k) V(z_k) + f_\theta(z_k)], \quad (7)$$

где $V(z) = zW^V$ — линейная проекция признаков по латентной оси ($W^V \in \mathbb{R}^{L \times L}$),

играющая роль value-проекции в attention. Слагаемое $f_\theta(z)$ — per-sensor реакционный MLP с pre-norm, по сути — FFN-блок графового трансформера. В корреляционном baseline и в чистом attention-варианте $f_\theta \equiv 0$.

4.4 Асимметричная матрица внимания

Центральный объект работы — матрица $\hat{A}(z)$. Для каждой моды $k = 1, \dots, K$ заведены две независимые линейные проекции [13]

$$W_k^Q, W_k^K \in \mathbb{R}^{L \times d}. \quad (8)$$

Модовая матрица определена как нормированная билинейная форма:

$$A_k(z) = \frac{(zW_k^Q)(zW_k^K)^\top}{\sqrt{d}} \in \mathbb{R}^{C \times C}. \quad (9)$$

Маршрутизирующая сеть R_ψ берёт пулированный по датчикам латент $\bar{z} = \frac{1}{C} \sum_i z_i \in \mathbb{R}^L$ и выдаёт распределение по модам:

$$w(z) = \text{softmax}(R_\psi(\bar{z})) \in \Delta^{K-1}. \quad (10)$$

Итоговое отображение:

$$\hat{A}(z) = \text{SN} \left(\sum_{k=1}^K w_k(z) A_k(z) \right), \quad (11)$$

где $\text{SN}(\cdot)$ — мягкая нормировка спектрального радиуса [5]: матрица делится на $\max(1, \hat{\sigma}_{\max}/r)$ с целевым $r = 1.5$ и оценкой $\hat{\sigma}_{\max}$ одной итерацией power method. Эта нормировка обеспечивает устойчивость итераций (7) без жёсткого ограничения на знак или величину отдельных A_{ij} .

Утверждение 3 (Симметричный частный случай). *Если $W_k^Q = W_k^K$ при всех k , то $A_k(z) = (zW_k^Q)(zW_k^Q)^\top / \sqrt{d} \in \mathcal{H}_{\text{sym}}$. Выпуклая комбинация остаётся симметричной, поэтому $\hat{A}(z) \in \mathcal{H}_{\text{sym}}$. Семейство моделей с этим ограничением совпадает с симметричным классом (определение 1).*

Утверждение 4 (Несвязанные проекции покрывают $\mathbb{R}^{C \times C}$). *При $W_k^Q \neq W_k^K$ и $d \geq C$ образ модового отображения $z \mapsto A_k(z)$ при изменении параметров покрывает весь $\mathbb{R}^{C \times C}$.*

Доказательство. Для произвольной $M \in \mathbb{R}^{C \times C}$ и фиксированного z_0 ранга C берём сингулярное разложение $M = U\Sigma V^\top$ и подбираем W_k^Q, W_k^K так, что $z_0 W_k^Q = U\sqrt{d}\Sigma^{1/2}$, $z_0 W_k^K = V\Sigma^{1/2}$. Тогда $A_k(z_0) = M$. $\square$

Следствие 2 (Иерархия семейств). *Симметричный класс $\mathcal{F}_\Theta^{\text{sym}} \subsetneq \mathcal{F}_\Theta$ — строгое подсемейство предложенной параметризации. Корреляционная модель, ядерные графы и tied-attention лежат в $\mathcal{F}_\Theta^{\text{sym}}$ и наследуют ограничение 1.*

Утверждения 3 и 4 формально замыкают основной тезис: предложенная архитектура обобщает симметричные методы, оставаясь способной восстанавливать асимметричные операторы связи.

4.5 Реакционный член

Реакция $f_\theta : \mathbb{R}^{C \times L} \rightarrow \mathbb{R}^{C \times L}$ задана как покомпонентный по датчикам MLP с предварительной нормализацией:

$$f_\theta(z) = W_2 \text{GELU}(W_1 \text{LN}(z)). \quad (12)$$

Веса W_2 инициализированы нулём, что обеспечивает старт с чистой диффузии. Реакционный член компенсирует нелинейные локальные эффекты, не сводимые к парному обмену через граф.

4.6 Декодер прогноза

Декодер $D : \mathbb{R}^L \rightarrow \mathbb{R}$ есть покомпонентная линейная проекция $D(z_i) = w_D^\top z_i$ с обучаемыми w_D . На каждом шаге rollout z_{k+1} декодируется в скалярную оценку $\hat{s}(t + (k+1)\Delta t)$ по каждому датчику.

Глава 5

Оптимизационная задача

5.1 Порождающая модель и вариационный нижний предел

Наблюдаемая динамика предполагается порождённой латентным процессом z через декодер автоэнкодера: при заданном z задержечный вектор Φ имеет порождающее распределение $p_\phi(\Phi \mid z)$. Приор по латенту — стандартный гауссовский: $p(z) = \mathcal{N}(0, I)$. Логарифм маргинального правдоподобия $\log p_\phi(\Phi)$ напрямую недоступен, и заменяется вариационным нижним пределом ELBO [3]:

$$\log p_\phi(\Phi) \geq \mathbb{E}_{q_\phi(z|\Phi)}[\log p_\phi(\Phi \mid z)] - \text{KL}(q_\phi(z \mid \Phi) \parallel p(z)). \quad (13)$$

Максимизация ELBO эквивалентна минимизации $-\text{ELBO}$, что в терминах MSE и замкнутой формы KL для гауссовских распределений даёт два слагаемых.

Реконструкционный член:

$$\mathcal{L}_{\text{rec}}(\theta_{\text{enc}}) = \frac{1}{|\mathcal{T}_{\text{tr}}|Cm} \sum_{t \in \mathcal{T}_{\text{tr}}} \|\Phi(t) - D_\phi(z(t))\|_2^2. \quad (14)$$

KL-член:

$$\mathcal{L}_{\text{KL}}(\theta_{\text{enc}}) = \frac{1}{|\mathcal{T}_{\text{tr}}|} \sum_{t \in \mathcal{T}_{\text{tr}}} \frac{1}{2} \sum_r (\mu_r^2 + \sigma_r^2 - 1 - \log \sigma_r^2). \quad (15)$$

Реконструкционный член обеспечивает информативность латента: z должен сохранять достаточно информации, чтобы Φ восстанавливался. KL-член предотвращает коллапс латента в дельта-функцию и выбирает гладкую параметризацию, согласованную с гауссовским приором. Минимизация ELBO даёт устойчивое низкоразмерное представление скрытой динамики — ровно в духе предположения о порождении наблюдаемых из латента.

5.2 Прогнозный лосс

Параметры пространственного блока обучаются по двум прогнозным функционалам. Многошаговый горизонтный лосс:

$$\mathcal{L}_{\text{pred}}(\theta) = \frac{1}{|\mathcal{T}_{\text{tr}}|HC} \sum_{t \in \mathcal{T}_{\text{tr}}} \sum_{k=1}^H \|s(t + k\Delta t) - \hat{s}_{\theta}(t + k\Delta t \mid t)\|_2^2, \quad (16)$$

где $\hat{s}_{\theta}(t + k\Delta t \mid t)$ строится итеративным применением (7) к $z(t)$ с последующим декодированием на каждом шаге. Внутриоконный одношаговый лосс:

$$\mathcal{L}_{\text{ind}}(\theta) = \frac{1}{|\mathcal{T}_{\text{tr}}|(W-1)C} \sum_t \sum_{j=0}^{W-2} \|s(t + (j+1)\Delta t) - D(z_{j+1}(t))\|_2^2. \quad (17)$$

Внутриоконный лосс даёт $W - 1$ обучающих точек на каждое окно — существенно больше, чем H точек от горизонтного лосса, и стабилизирует обучение пространственного блока.

5.3 Регуляризатор маршрутизации

Маршрутизирующая сеть склонна к коллапсу: оптимизатор может сходиться к постоянному w , при котором K мод вырождаются в одну эффективную пару проекций. Чтобы предотвратить это, к лоссу добавляется штраф за неравномерность маргинального по батчу распределения режимов

$$\bar{w}(B) = \frac{1}{|B|} \sum_{t \in B} w(z(t)), \quad (18)$$

$$\mathcal{L}_{\text{reg}}(\theta) = \log K - \mathbb{H}(\bar{w}(B)) = \text{KL}(\text{Uniform}\{1, \dots, K\} \parallel \bar{w}(B)) \geq 0. \quad (19)$$

Дополнительно финальный слой R_{ψ} инициализирован нулём, что даёт равномерное стартовое w .

5.4 Совокупная задача оптимизации

Полный функционал

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{pred}} + \lambda_1 \mathcal{L}_{\text{ind}} + \lambda_2 \mathcal{L}_{\text{rec}} + \lambda_3 \mathcal{L}_{\text{KL}} + \lambda_4 \mathcal{L}_{\text{reg}}, \quad (20)$$

объединяет:

1. реконструкцию динамики ($\mathcal{L}_{\text{pred}}$ и $\mathcal{L}_{\text{ind}}$): согласованность модели с наблюдаемой траекторией;

2. согласование графовой структуры ($\mathcal{L}_{\text{ind}}$): каждый шаг лосса требует, чтобы $\hat{A}(z)$ корректно предсказывал следующее наблюдение;
3. снижение размерности ($\mathcal{L}_{\text{rec}}$ и $\mathcal{L}_{\text{KL}}$): латент удерживается компактным и регулярным;
4. генеративное моделирование ($\mathcal{L}_{\text{rec}} + \mathcal{L}_{\text{KL}}$ есть $-\text{ELBO}$ автоэнкодера).

Задача оптимизации:

$$\theta^* \in \arg \min_{\theta \in \Theta} \mathcal{L}(\theta), \quad (21)$$

$\theta = (\theta_{\text{enc}}, \theta_{\text{temp}}, \theta_{\text{op}}, \alpha_0, \psi, \theta_{\text{dec}})$. Решается AdamW с косинусным расписанием learning rate; все блоки обучаются совместно.

Корреляционный baseline получается изоляцией θ_{op} к симметричному подсемейству: вместо банка с W_k^Q, W_k^K используется заранее посчитанная нормированная корреляция $\hat{\Sigma}$, и обучаемой остаётся только её скалярная амплитуда γ .

Глава 6

Вычислительный эксперимент

6.1 Сценарии

Эксперимент проведён на двух датасетах. Первый — контролируемая синтетическая система с заранее известным истинным оператором $A(u)$, позволяющая прямо сравнивать восстановленную модель с истиной. Второй — реальные EEG-данные моторного воображения из открытой коллекции PhysioNet eegbci [9], проверяющие применимость подхода вне синтетики.

6.2 Синтетический датасет: кольцо с дрейфующим ядром

Распределённая система задана на одномерном кольце из $C = 32$ датчиков. Эволюция наблюдений определяется циркулянтным оператором, первая строка которого пропорциональна гауссиане со смещением; центр смещения $v(t)$ переключается каждые 500 шагов между двумя значениями $+v_0$ и $-v_0$. Это даёт бинарное чередование режимов переноса вправо и влево. Истинный оператор связи в каждом режиме обладает асимметрией $\|A - A^\top\|_F / \|A\|_F \approx 1,41$, а усреднённый по двум режимам оператор симметричен. К наблюдениям добавляется аддитивный гауссовский шум $\sigma = 0,3$, ряд стандартизуется поканально. Длина обучающей траектории $T = 30000$.

6.3 Реальный датасет: EEG моторного воображения

Используется один испытуемый из PhysioNet eegbci [9], эксперименты 4, 8, 12 (motor imagery левой и правой руки), $C = 64$ электрода, sfreq 160 Гц, сегмент длиной 30000 отсчётов после полосовой фильтрации 1–40 Гц и стандартизации поканально.

6.4 Сравнимые модели

Все три модели разделяют общий VAE-энкодер, временной трансформер, правило rollout, декодер и весовые коэффициенты лосса. Различие сосредоточено в простран-

ственном блоке:

1. Корреляция: $\hat{A}(z) = \gamma \hat{\Sigma}$, где $\hat{\Sigma}$ — предвычисленная Pearson-корреляция наблюдений тренировочной части, нормированная на свой спектральный радиус. Симметричный baseline, представляющий симметричный класс из определения 1.
2. Асимметричный graph attention: $\hat{A}(z)$ из банка (11) с несвязанными W_k^Q, W_k^K ; реакционный член $f_\theta \equiv 0$.
3. Graph attention с реакцией: то же $\hat{A}(z)$ плюс реакционный MLP $f_\theta(z)$.

6.5 Параметры обучения

Длина окна $W = 32$, отбрасываемый warmup 8, горизонт $H = 4$. Размерность энкодера $d_{\text{model}} = 32$, $L = m$ (без сжатия в координатной оси). Число мод банка $K = 2$ на синтетике и $K = 3$ на EEG. Скрытая размерность голов $d = 16$. Целевой спектральный радиус $r = 1,5$. Коэффициенты лосса: $\lambda_2 = 0,1$, $\lambda_3 = 10^{-4}$, $\lambda_4 = 0,05$, $\lambda_1 = 1$. Оптимизатор AdamW, learning rate $3 \cdot 10^{-3}$, косинусное расписание, 30 эпох на синтетике, 50 на EEG, batch size 128. Сплит 80/20 по времени.

6.6 Метрики

Качество прогноза измеряется среднеквадратичной ошибкой по горизонту (16), усреднённой по тестовой выборке и каналам. Качество восстановления оператора связи (на синтетике, где известно истинное A):

- асимметрия восстановленного $\hat{A}$: $\|\hat{A} - \hat{A}^\top\|_F / \|\hat{A}\|_F$;
- линейная корреляция $\rho(\hat{A}_\pm, A_\pm)$ по режиму — между восстановленным и истинным оператором в каждом из двух режимов.

6.7 Результаты на синтетике

Сводные числа на отложенной выборке приведены в табл. 1.

Таблица 1. Синтетика (кольцо $C = 32$, бинарные режимы). MSE — средний по горизонту; asym — асимметрия $\|\hat{A} - \hat{A}^\top\|_F / \|\hat{A}\|_F$ для режима $+v_0$; $\rho(\hat{A}_+, A_+)$ — корреляция с истинным оператором того же режима; $\rho(\hat{A}_+, A_-)$ — с противоположного. Истинная асимметрия $\approx 1,41$.

Модель	MSE	asym $\hat{A}_+$	$\rho(\hat{A}_+, A_+)$	$\rho(\hat{A}_+, A_-)$
Корреляция	0,202	≈ 0	+0,444	+0,444
GA, асимм.	0,183	1,337	+0,083	−0,285
GA + reaction	0,158	0,447	+0,149	−0,221

Содержательные наблюдения:




Рис. 2. Синтетика: средние восстановленные матрицы $\hat{A}$ для трёх моделей и MSE прогноза по шагам горизонта. У корреляции матрица идентична для обоих режимов; у GA-моделей структура зависит от состояния.

1. Корреляционный baseline даёт асимметрию ≈ 0 по построению и одинаковую корреляцию $+0,44$ с обоими истинными режимами. Это в точности предсказание следствия 1: модель не способна различать направления переноса.
2. GA, асимм. восстанавливает асимметрию $1,34$ — близко к истинной $1,41$. Корреляция со своим режимом положительна ($+0,08$), с противоположным — отрицательна ($-0,29$). Модель различает направления переноса, что прямо подтверждает основной тезис работы.
3. GA с реакцией получает лучший MSE прогноза ($0,158$ против $0,202$ у корреляции, выигрыш 22%). Асимметрия восстановленного оператора у него ниже, чем у чистой GA ($0,45$ против $1,34$): реакционный член забирает на себя часть направленной структуры, перенося её из парного графового обмена в локальный нелинейный шаг.

Иерархия согласована с теорией: переход от симметричного класса $\mathcal{F}_{\Theta}^{\text{sym}}$ к полному $\mathcal{F}_{\Theta}$ устраняет неустранимую границу из утверждения 2 и снижает практический MSE.

6.8 Результаты на EEG

Сводные числа приведены в табл. 2. Истинный оператор $A(u)$ для EEG недоступен; асимметрия $\hat{A}$ приведена только как структурная характеристика выученной

модели.

Таблица 2. EEG motor imagery, $C = 64$, 30000 отсчётов.

Модель	MSE	asym $\hat{A}$
Корреляция	0,426	≈ 0
GA, асимм.	0,408	0,012
GA + reaction	0,432	0,219

Наблюдения:

1. GA, асимм. снижает MSE на 4 % относительно корреляции (0,408 против 0,426). Это меньший выигрыш, чем на синтетике: в EEG моторного воображения сырой сигнал содержит куда менее выраженную направленную связь, и большая часть полезной информации лежит в симметричной составляющей.
2. GA с реакцией немного уступает на длинном горизонте: реакционный MLP здесь overfits на сырых отсчётах без дополнительной предобработки (например, без полосовой фильтрации в alpha/beta-диапазоне).
3. Структурно: на матрицах видны функциональные блоки EEG — кластеры моторной коры (Cz и соседние), фронтальные и височные группы. Это указывает, что модель улавливает анатомически осмысленную структуру связей даже на коротких сегментах.

.

6.9 Связь результатов с основным тезисом

Эксперимент подтверждает основной тезис в трёх плоскостях:

- Выразительность: симметричная корреляция имеет нулевую асимметрию по построению и одинакова для обоих режимов; предложенная асимметричная модель восстанавливает асимметрию, близкую к истинной.
- Геометрия связей: $\rho(\hat{A}_+, A_-)$ становится отрицательной у GA-моделей, что означает явное различие режимов; у корреляции эта величина равна $\rho(\hat{A}_+, A_+)$ тождественно.
- Качество прогноза: на синтетике с заведомо асимметричным переносом MSE снижается на 22 %, что согласовано с утверждением 1 (симметричный класс имеет неустранимый зазор от истины).




Рис. 3. EEG: матрицы банка ядер с $K = 3$ режимами. У асимметричного graph-attention (без реакции) все три моды используются примерно равномерно ($\bar{w} \approx 1/3$); содержательная блочная структура каналов выражена сильнее у варианта с реакционным MLP.

Глава 7

Заключение

В работе сформулирован и подтверждён тезис о том, что асимметричная матрица внимания, построенная на основе геометрии фазового пространства, лучше подходит для предсказания и восстановления скрытых зависимостей, чем классическая симметричная корреляционная матрица. Показано принципиальное ограничение симметричных моделей: их образ лежит в подпространстве $\mathcal{H}_{\text{sym}}$, и любой симметричный аппроксиматор имеет неустранимую ошибку $\|A_{\text{asym}}\|_F$ относительно истинного оператора связи.

Предложена параметризация на базе банкованного multi-head attention с несвязанными проекциями запросов и ключей. Класс снимает симметричное ограничение и покрывает всё пространство $\mathbb{R}^{C \times C}$. Симметричные модели — корреляционные, ядерно-графовые, tied-attention — являются строгим частным случаем предложенного класса при равенстве проекций. Это позволяет одной архитектурой обобщить существующие подходы и одновременно дать модели возможность выходить за пределы симметричной части.

Архитектура замыкается на двух уровнях редукции. На уровне состояния используется VAE [3] над задержечными координатами Такенса [11, 8]; ELBO даёт устойчивое низкоразмерное представление, согласованное с гауссовским priorом. На уровне оператора пространственная динамика реализована как residual graph-attention блок с банком асимметричных матриц сходств [13, 14] и опциональным реакционным MLP; Альтернативные подходы к data-driven редукции для управления — Коорман-операторный анализ [1], динамическое модовое разложение с управлением [7], LPV-планирование [6] — остаются естественными downstream-приложениями полученной модели.

Эмпирическая проверка на синтетике с заведомо асимметричным оператором подтверждает основной тезис: предложенная модель снижает MSE прогноза на 22 % относительно симметричного baseline, восстанавливает направленность переноса и корректно разделяет режимы. На реальных данных EEG моторного воображения наблюдается аналогичный, хотя и более скромный, прирост.

Дальнейшие направления исследования включают применение к задачам с явно

адвекционной структурой (трафик, климатические сети), систематическое исследование числа мод K и максимального спектрального радиуса r , а также интеграцию полученной редуцированной модели в контуры прогнозного управления.

Литература

- [1] Steven L. Brunton, Bingni W. Brunton, Joshua L. Proctor, and J. Nathan Kutz. Koopman invariant subspaces and finite linear representations of nonlinear dynamical systems for control. *PLOS ONE*, 11(2):e0150171, 2016.
- [2] Clive W. J. Granger. Investigating causal relations by econometric models and cross-spectral methods. *Econometrica*, 37(3):424–438, 1969.
- [3] Diederik P. Kingma and Max Welling. Auto-encoding variational Bayes. In *International Conference on Learning Representations (ICLR)*, 2014.
- [4] Yaguang Li, Rose Yu, Cyrus Shahabi, and Yan Liu. Diffusion convolutional recurrent neural network: data-driven traffic forecasting. In *International Conference on Learning Representations (ICLR)*, 2018.
- [5] Takeru Miyato, Toshiki Kataoka, Masanori Koyama, and Yuichi Yoshida. Spectral normalization for generative adversarial networks. In *International Conference on Learning Representations (ICLR)*, 2018.
- [6] Javad Mohammadpour and Carsten W. Scherer, editors. *Control of Linear Parameter Varying Systems with Applications*. Springer, 2012.
- [7] Joshua L. Proctor, Steven L. Brunton, and J. Nathan Kutz. Dynamic mode decomposition with control. *SIAM Journal on Applied Dynamical Systems*, 15(1):142–161, 2016.
- [8] Tim Sauer, James A. Yorke, and Martin Casdagli. Embedology. *Journal of Statistical Physics*, 65(3–4):579–616, 1991.
- [9] Gerwin Schalk, Dennis J. McFarland, Thilo Hinterberger, Niels Birbaumer, and Jonathan R. Wolpaw. BCI2000: a general-purpose brain-computer interface (BCI) system. *IEEE Transactions on Biomedical Engineering*, 51(6):1034–1043, 2004.
- [10] George Sugihara, Robert May, Hao Ye, Chih-hao Hsieh, Ethan Deyle, Michael Fogarty, and Stephan Munch. Detecting causality in complex ecosystems. *Science*, 338(6106):496–500, 2012.

- [11] Floris Takens. Detecting strange attractors in turbulence. In David A. Rand and Lai-Sang Young, editors, *Dynamical Systems and Turbulence, Warwick 1980*, volume 898 of *Lecture Notes in Mathematics*, pages 366–381. Springer, 1981.
- [12] Roger Temam. *Infinite-Dimensional Dynamical Systems in Mechanics and Physics*, volume 68 of *Applied Mathematical Sciences*. Springer, 2 edition, 1997.
- [13] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 5998–6008, 2017.
- [14] Petar Veličković, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Liò, and Yoshua Bengio. Graph attention networks. In *International Conference on Learning Representations (ICLR)*, 2018.