

Министерство образования и науки Российской Федерации
Московский физико-технический институт (национальный
исследовательский университет)

Физтех-школа прикладной математики и информатики
Кафедра интеллектуальных систем

Выпускная квалификационная работа бакалавра по направлению 010900
«Прикладные математика и физика»

Снижение размерности латентного пространства в задачах управления

Студент Б05-251л группы
Астахов А. М.

Научный руководитель
д. ф.-м. н. Стрижов В.В.

Долгопрудный
2026

Содержание

1. Аннотация	1
2. Введение	2
3. Формальная постановка задачи	4
3.1. Пространство состояний и наблюдения	4
3.2. Задержечное представление состояния	4
3.3. Локально-линейное представление и оператор связи	5
3.4. Симметричное и антисимметричное разложение	5
3.5. Симметричные модели и принципиальное ограничение	5
3.6. Задачи	6
4. Формальное описание модели	8
4.1. Автоэнкодер над координатами Такенса	9
4.2. Выбор числа мод	9
4.3. Временной трансформер в латенте	10
4.4. Граф датчиков и residual graph attention	10
4.5. Асимметричная матрица внимания и жёсткий маршрутизатор Гумбеля	10
4.6. Реакционный член	12
4.7. Декодер прогноза	12
5. Оптимизационная задача	13
5.1. Реконструкционный лосс автоэнкодера	13
5.2. Прогнозный лосс	13
5.3. Регуляризатор маршрутизации	14
5.4. Регуляризатор фазы	14
5.5. Совокупная задача оптимизации	15
6. Вычислительный эксперимент	16
6.1. Сценарии	16
6.2. Синтетический датасет: кольцо с дрейфующим ядром	16
6.3. Реальный датасет: ЭЭГ моторного воображения	16
6.4. Сравнимые модели	17
6.5. Параметры обучения	17
6.6. Метрики	17

6.7. Результаты на синтетике	17
6.8. Результаты на ЭЭГ	19
6.9. Анализ восстановленных матриц связности	20
6.9.1. Синтетика: drift-ring	20
6.9.2. ЭЭГ	21
6.10. Обсуждение результатов	21
7. Заключение	28

Глава 1

Аннотация

Работа посвящена задаче снижения размерности латентного пространства в задачах прогнозирования и управления распределёнными динамическими системами по данным сети датчиков. Ключевой объект — оператор связности $A(u) \in \mathbb{R}^{C \times C}$, описывающий попарные направленные взаимодействия между датчиками. Этот оператор в общем случае асимметричен: $A_{ij} \neq A_{ji}$. Стандартные подходы (корреляция Пирсона, ядерные графы, tied-attention) по построению симметричны, что влечёт принципиальную нижнюю границу ошибки аппроксимации, равную $\|A_{\text{asym}}\|_F^2$ и не устранимую ни объёмом данных, ни числом параметров.

Предлагается подход, в котором снижение размерности задержечных координат Такенса до латентного пространства сохраняет прогностически значимую динамику и позволяет аппроксимировать оператор связности низкоранговой структурой, не ограниченной симметричным подпространством. Реализация выполнена в виде архитектуры **MoE-GA** (Mixture-of-Experts Graph Attention), объединяющей детерминированный автоэнкодер над координатами Такенса и смесь несвязанных асимметричных экспертов с жёстким маршрутизатором Гумбеля. Совместная минимизация прогнозного функционала, реконструкционного лосса автоэнкодера и регуляризатора фазы обеспечивает согласованное снижение размерности и обучение оператора связности.

Эксперименты проведены на двух наборах данных. На синтетической системе (drift-ring, $C = 16$) с заведомо асимметричным оператором модель MoE-GA Full снижает MSE прогноза на 11,1 % и восстанавливает антисимметричную составляющую ($A_{\text{asym}} = 0,255$ против ≈ 0 у базиса). На реальных данных ЭЭГ моторного воображения (PhysioNet EEGBCI, $C = 64$) прирост составляет 6,8 %, что подтверждает применимость подхода к реальным нейрофизиологическим сигналам.

Глава 2

Введение

Прогноз и управление распределёнными динамическими системами сталкиваются с двумя трудностями. Во-первых, истинное состояние системы — поле или вектор большой размерности, наблюдаемый лишь через конечный набор датчиков. Во-вторых, связи между датчиками, как правило, не статичны: фаза, режим, локальные условия определяют, кто на кого и насколько влияет в данный момент. Эффективная редуцированная модель должна одновременно учитывать оба обстоятельства.

Классический путь снижения размерности в этой задаче — построение графа связей между датчиками и обучение динамики на этом графе. Простейшая и исторически популярная конструкция использует попарную корреляцию Пирсона: $\hat{\Sigma}_{ij} = \text{corr}(s_i, s_j)$. Эта матрица симметрична по построению. Аналогично симметричны ядерные графы вида $\kappa(\|\xi_i - \xi_j\|)$, а также классическое self-attention [15] при условии $W^Q = W^K$, когда оператор внимания сводится к матрице Грама. Объединяя эти примеры, получаем обширный класс симметричных моделей связности, для которого $\hat{A}_{ij} = \hat{A}_{ji}$ выполнено тождественно.

Между тем, во многих практически значимых системах связь между датчиками существенно направлена. Адвекционные процессы переносят информацию по потоку (атмосфера, реки, трафик; типичный пример — графовое прогнозирование дорожного трафика через диффузионную рекуррентную сеть [6]); причинно-следственные сети нейрофизиологических и климатических сигналов организованы иерархически и для них формализована Granger-причинность [3] и сходящееся кросс-отображение [12]; финансовые рынки демонстрируют lead-lag-эффекты между регионами. Антисимметричная часть истинного оператора связи $A(u) = A_{\text{sym}}(u) + A_{\text{asym}}(u)$ несёт информацию о направленности; при симметризации эта часть полностью теряется.

Этим мотивирована геометрическая постановка задачи: представить динамику как процесс на графе, в котором сами рёбра ориентированы и взвешены неравными скалярами $A_{ij} \neq A_{ji}$. Конструктивная реализация такого процесса — обучаемое распространение информации по графу через механизм внимания с независимыми проекциями запросов и ключей [15, 16], при итеративном применении с residual-связью. Для выбора актуального режима вводится маршрутизирующая сеть, реализующая

жёсткий Гумбелевский выбор [4]: в каждый момент активируется ровно один эксперт из смеси, что принципиально сокращает паразитный градиентный сигнал от «мёртвых» голов и упрощает интерпретацию.

Низкоразмерное представление состояния необходимо по двум причинам. Первая — содержательная: наблюдаемая динамика, согласно гипотезе существования инерциального многообразия [14], порождается конечномерным латентным процессом, и работа в его координатах геометрически корректна. Вторая — вычислительная: задержечные координаты Такенса [13, 10] дают избыточное, шумное представление большой размерности; автоэнкодер сжимает эти координаты до компактного латентного представления, обучаемого совместно с прогнозной моделью динамики через реконструкционный лосс и прогнозные лоссы. Число активных режимов определяется либо из данных по спектральным критериям, либо задаётся вручную в соответствии с физической структурой системы.

Связь с задачами управления. Предиктивная модель динамической системы является ключевым компонентом контуров предиктивного управления (Model Predictive Control, MPC): контроллер строит оптимальное управляющее воздействие, минимизируя прогнозируемое отклонение от целевой траектории. Точность и компактность модели напрямую определяют качество управления. Снижение размерности латентного пространства (с $C \times m$ до $C \times L$) делает модель вычислительно пригодной для использования в контуре управления в реальном времени, а асимметричный оператор связности обеспечивает физически корректное описание направленного переноса информации — необходимое условие для синтеза управляющих воздействий в системах с потоковой или причинно-следственной структурой взаимодействий.

Глава 3

Формальная постановка задачи

3.1 Пространство состояний и наблюдения

Пусть $\Omega \subset \mathbb{R}^n$ — ограниченная область с кусочно-гладкой границей, $n \in \{1, 2, 3\}$. Рассматривается распределённая динамическая система с фазовым пространством $\mathcal{M} = L^2(\Omega)$ — пространством квадратично-интегрируемых по Лебегу функций на Ω . Эволюция задана однопараметрическим оператором $\varphi : \mathbb{R}_{\geq 0} \times \mathcal{M} \rightarrow \mathcal{M}$, не предполагаемым линейным.

Предположение 1 (Конечномерный аттрактор). Существует компактное φ -инвариантное множество $\mathcal{A} \subset \mathcal{M}$ конечной бокс-размерности $d_{\mathcal{A}} < \infty$, на которое все траектории сходятся. Элементы $\mathcal{A}$ обозначаются u и считаются скрытым состоянием системы.

Наблюдение производится в фиксированных пространственных точках $\xi_1, \dots, \xi_C \in \Omega$ через гладкие функции $h_i : \mathcal{M} \rightarrow \mathbb{R}$. Вектор наблюдений

$$s(t) = (h_1(u(t)), \dots, h_C(u(t))) \in \mathbb{R}^C, \quad u(t) \in \mathcal{A}. \quad (1)$$

Доступные данные — дискретная траектория $\mathcal{D} = \{s(t_n)\}_{n=0}^N$ с равномерным шагом $t_n = n\Delta t$.

3.2 Задержечное представление состояния

Скрытое $u(t)$ напрямую не наблюдается. Теорема Такенса о вложении по задержкам [13] и её обобщение для многосенсорных и фрактальных аттракторов [10] утверждают, что для гладких h_i и подходящих $\tau > 0$, $m \in \mathbb{N}$ отображение

$$\Phi(t) = (s_i(t - j\tau))_{i=1, \dots, C; j=0, \dots, m-1} \in \mathbb{R}^{C \times m} \quad (2)$$

при $Cm \geq 2d_{\mathcal{A}} + 1$ является погружением $\mathcal{A}$ в евклидово пространство. Это позволяет заменить ненаблюдаемое состояние u на наблюдаемые координаты $\Phi(u)$, согласованные с геометрией аттрактора.

3.3 Локально-линейное представление и оператор связи

Утверждение 1 (Локальная линеаризация). При C^1 -гладкости $\varphi_{\Delta t}$ и h существует отображение $A : \mathcal{A} \rightarrow \mathbb{R}^{C \times C}$ такое, что

$$s(t + \Delta t) = A(u(t)) s(t) + \eta(t), \quad \mathbb{E}[\eta(t) \mid \mathcal{F}_t] = 0, \quad (3)$$

с точностью до $o(\Delta t)$. Матрица $A(u)$ называется оператором связи между датчиками.

3.4 Симметричное и антисимметричное разложение

Введём скалярное произведение Фробениуса $\langle P, Q \rangle_F = \text{tr}(P^\top Q)$ и подпространства $\mathcal{H}_{\text{sym}} = \{M : M^\top = M\}$ и $\mathcal{H}_{\text{asym}} = \{M : M^\top = -M\}$.

Лемма 1 (Ортогональное разложение). Пространство $\mathbb{R}^{C \times C}$ есть ортогональная прямая сумма $\mathcal{H}_{\text{sym}} \oplus \mathcal{H}_{\text{asym}}$ с размерностями $\dim \mathcal{H}_{\text{sym}} = C(C + 1)/2$ и $\dim \mathcal{H}_{\text{asym}} = C(C - 1)/2$. Любая $A \in \mathbb{R}^{C \times C}$ единственным образом раскладывается

$$A = A_{\text{sym}} + A_{\text{asym}}, \quad A_{\text{sym}} = \frac{1}{2}(A + A^\top), \quad A_{\text{asym}} = \frac{1}{2}(A - A^\top), \quad (4)$$

причём $\|A\|_F^2 = \|A_{\text{sym}}\|_F^2 + \|A_{\text{asym}}\|_F^2$.

Доказательство. При $P^\top = P$, $Q^\top = -Q$ имеем $\text{tr}(P^\top Q) = \text{tr}(PQ) = \text{tr}((PQ)^\top) = \text{tr}(Q^\top P^\top) = \text{tr}(-QP) = -\text{tr}(PQ)$, откуда $\text{tr}(PQ) = 0$, то есть $\mathcal{H}_{\text{sym}} \perp \mathcal{H}_{\text{asym}}$. Размерности: пространство симметричных матриц $C \times C$ параметризуется диагональными элементами (C штук) и верхнетреугольными ($C(C - 1)/2$ штук), итого $\dim \mathcal{H}_{\text{sym}} = C(C + 1)/2$; аналогично, кососимметричные матрицы имеют нулевую диагональ и $C(C - 1)/2$ независимых наддиагональных элементов, откуда $\dim \mathcal{H}_{\text{asym}} = C(C - 1)/2$. Сумма размерностей $C(C + 1)/2 + C(C - 1)/2 = C^2 = \dim \mathbb{R}^{C \times C}$ подтверждает прямую сумму. Единственность разложения следует из ортогональности подпространств, а равенство норм — из теоремы Пифагора для ортогональной суммы. $\square$

3.5 Симметричные модели и принципиальное ограничение

Определение 1 (Симметричный класс). Семейство параметризованных моделей $\hat{A}_\theta(z)$ называется симметричным, если $\hat{A}_\theta(z) \in \mathcal{H}_{\text{sym}}$ для всех θ и z .

Корреляционная модель $\hat{A} = \gamma \hat{\Sigma}$ принадлежит симметричному классу. К нему же относятся ядерные графы и self-attention с $W^Q = W^K$: произведение $zW^Q(zW^Q)^\top$ есть матрица Грама, симметричная по построению.

Утверждение 2 (Нижняя граница ошибки симметричной аппроксимации). Для любой $A \in \mathbb{R}^{C \times C}$ и любой $M \in \mathcal{H}_{\text{sym}}$

$$\|A - M\|_F^2 \geq \|A_{\text{asym}}\|_F^2 = \frac{1}{4}\|A - A^\top\|_F^2, \quad (5)$$

с равенством при $M = A_{\text{sym}}$.

Доказательство. $A - M = (A_{\text{sym}} - M) + A_{\text{asym}}$ — ортогональная сумма по лемме 1; теорема Пифагора даёт неравенство. $\square$

Следствие 1 (Принципиальная потеря). *Если истинный оператор $A(u)$ имеет ненулевую антисимметричную часть $A_{\text{asym}}(u)$, то любая симметричная модель имеет неустранимую среднюю ошибку аппроксимации, равную $\mathbb{E} \|A_{\text{asym}}(u)\|_F^2$. Эта ошибка не уменьшается ни увеличением числа параметров, ни увеличением объёма данных.*

Следствие 1 показывает, что для систем с ненулевой антисимметричной составляющей оператора связи любой симметричный аппроксиматор несёт принципиально неустранимую ошибку, не зависящую ни от объёма данных, ни от числа параметров модели. Это обосновывает необходимость выхода за пределы симметричного класса.

3.6 Задачи

Класс рассматриваемых динамических систем. Рассматриваются нелинейные нестационарные системы с переключением режимов: оператор связности $A(u(t))$ меняется в зависимости от скрытого состояния $u(t)$. Частный случай — системы с конечным числом режимов (LPV-системы [9]), где $A \in \{A_1, \dots, A_K\}$ в зависимости от текущего режима. Синтетическая система drift-ring явно принадлежит этому классу: оператор переключается между двумя фиксированными значениями T_+ и T_- с известным правилом. Для ЭЭГ моторного воображения принадлежность к LPV-классу принимается как моделирующая гипотеза, согласующаяся с нейрофизиологической литературой о переключении функциональных состояний мозга, однако не является доказанным фактом в строгом смысле.

Замечание 1 (Параметризация через реконструированный аттрактор). Скрытое состояние $u(t) \in \mathcal{A}$ напрямую не наблюдается. Теорема Такенса гарантирует лишь существование гомеоморфизма $\Psi : \mathcal{A} \rightarrow \Psi(\mathcal{A}) \subset \mathbb{R}^{C \times m}$, сопоставляющего скрытому состоянию наблюдаемые задержечные координаты. Поэтому параметризация оператора A через аргумент z в настоящей работе понимается не как функция исходного состояния u , а как функция на образе реконструированного аттрактора $\Psi(\mathcal{A})$: вместо недоступного $A(u)$ обучается $\hat{A}_\theta(z)$, где $z = z(\Phi(u))$ — латентное представление задержечных координат. Корректность такой параметризации следует из того, что Ψ — гомеоморфизм, и любая непрерывная функция на $\mathcal{A}$ может быть реализована как непрерывная функция на $\Psi(\mathcal{A})$.

Матрица связности и её свойства. Оператор $A(u) \in \mathbb{R}^{C \times C}$ характеризует попарные направленные взаимодействия между датчиками. В общем положении $A_{ij} \neq A_{ji}$: датчик j может влиять на датчик i сильнее, чем i на j . По следствию 1, любая

симметричная аппроксимация $\hat{A} \in \mathcal{H}_{\text{sym}}$ имеет неустранимую ошибку $\|A_{\text{asym}}\|_F^2$, не зависящую от объёма данных. Предлагаемая модель строит оператор $\hat{A}_\theta(z) \notin \mathcal{H}_{\text{sym}}$ в редуцированном латентном пространстве.

По траекториям $\mathcal{D}$ требуется:

1. построить низкоразмерное представление $z(t) \in \mathbb{R}^{C \times L}$, $L = \text{round}(m \times 2/3)$, скрытого состояния системы, согласованное с теоремой Такенса;
2. построить параметризованное отображение $\hat{A}_\theta : z \mapsto \mathbb{R}^{C \times C}$, не ограниченное симметричным подпространством $\mathcal{H}_{\text{sym}}$;
3. обучить модель прогноза $s(t + k\Delta t)$ на горизонте H через итеративную динамику в латенте.

Глава 4

Формальное описание модели

Архитектура **MoE-GA** (Mixture-of-Experts Graph Attention) состоит из четырёх блоков: детерминированного автоэнкодера над задержечными векторами Такенса [13], временного трансформера [15] в латенте, пространственного оператора с асимметричной матрицей внимания и жёстким Гумбелевским маршрутизатором [4], а также покомпонентного декодера. Вариант **MoE-GA Full** дополнительно содержит реакционный MLP. Общая схема показана на рис. 1.




Рис. 1. Схема модели MoE-GA. Состояние сжимается до латента $z(t)$ размерности $L = \text{round}(m \times 2/3)$; жёсткий маршрутизатор Гумбеля выбирает ровно одного эксперта из смеси K компонент; выбранное ядро даёт асимметричный оператор $\hat{A}(z)$, по которому далее выполняется один residual-шаг graph attention. В варианте MoE-GA Full дополнительно присутствует реакционный член $f_\theta(z)$.

4.1 Автоэнкодер над координатами Такенса

Для каждого датчика i строится задержечный вектор $\Phi_i(t) = (s_i(t), s_i(t-\tau), \dots, s_i(t-(m-1)\tau)) \in \mathbb{R}^m$. Параметры τ и m выбираются глобально по всем датчикам: τ — первый локальный минимум усреднённой по сенсорам взаимной информации, m — наименьшее значение, при котором средняя по датчикам доля ложных ближайших соседей опускается ниже порога.

Энкодер состоит из двух этапов. Первый — покомпонентный (по датчикам) каузальный трансформерный блок [15], обрабатывающий временную ось каждого датчика независимо. Второй — некаузальный пространственный блок, вычисляющий между-сенсорное внимание внутри одного окна; он позволяет кодировщику учитывать корреляцию соседних датчиков при построении латента.

Совокупно энкодер $E_{\theta_{\text{enc}}}$ переводит $\Phi_i(t)$ в латентный вектор детерминированным отображением

$$z_i(t) = \mu_\phi(\Phi_i(t)) \in \mathbb{R}^L, \quad (6)$$

где $\mu_\phi : \mathbb{R}^m \rightarrow \mathbb{R}^L$ — параметрическая функция (выход энкодера). Размерность латента

$$L = \text{round}\left(m \times \frac{2}{3}\right), \quad (7)$$

что даёт сжатие примерно на $1/3$ относительно исходных координат Такенса; значение (7) вычисляется на этапе постановки эксперимента и передаётся в модель как аргумент. Отображение $z_i(t) = \mu_\phi(\Phi_i(t))$ применяется одинаково на обучении и на выводе, без сэмплирования и случайного шума. Декодер автоэнкодера $D_\phi : \mathbb{R}^L \rightarrow \mathbb{R}^m$ восстанавливает исходный задержечный вектор Φ_i по z_i ; качество восстановления контролируется реконструкционным лоссом $\mathcal{L}_{\text{rec}}$ (раздел 5), обучаемым совместно с прогнозными потерями и регуляризатором фазы.

4.2 Выбор числа мод

Число экспертов K — гиперпараметр модели. Для задач с достаточной длиной ряда предлагается автоматический выбор из данных:

$$K = \max(K_{\text{MP}}, K_{\text{bands}}, K_{\text{rank}}), \quad (8)$$

где K_{MP} — число собственных значений матрицы задержечных ковариаций, превышающих порог Марченко–Пастура, K_{bands} — число значимых частотных полос, K_{rank} — наименьшее ранговое покрытие, достаточное для объяснения заданной доли дисперсии.

В эксперименте на ЭЭГ правило (8) применяется автоматически и даёт $K = 4$ ($K_{\text{MP}} = 4$ доминирует). На синтетической задаче drift-ring длина ряда мала ($T = 3000$), поэтому K задаётся вручную: $K = 6$, что перекрывает два физических режима переноса с запасом по числу экспертов.

4.3 Временной трансформер в латенте

Латентная траектория $z(t) \in \mathbb{R}^{C \times L}$ дополнительно обрабатывается каузальным трансформером, действующим по временной оси независимо для каждого датчика. Это аккумулирует временной контекст в латенте без смещения сенсоров и поднимает качество оценки $z(t)$ в окрестности границы окна, где автоэнкодер видит короткий контекст.

4.4 Граф датчиков и residual graph attention

Пусть $\mathcal{G} = (V, E)$ — полный направленный граф на C вершинах, где каждый узел i соответствует датчику ξ_i . Ребро (i, j) взвешено скаляром $A_{ij}(z) \in \mathbb{R}$, в общем случае не равным $A_{ji}(z)$. Содержательно $A(z)$ есть обучаемая матрица попарных сходств между датчиками в текущем латентном состоянии [15, 16]; от классического self-attention отличается тем, что проекции запросов и ключей несвязаны (см. раздел 4.5), а softmax-нормировка по строкам заменена мягким контролем спектрального радиуса.

Обновление латента — residual-шаг graph attention с обучаемой скалярной величиной $\alpha = \sigma(\alpha_0) \in (0, 1)$:

$$z_{k+1} = z_k + \alpha [\hat{A}(z_k) V(z_k) + f_\theta(z_k)], \quad (9)$$

где $V(z) = zW^V$ — линейная проекция признаков по латентной оси ($W^V \in \mathbb{R}^{L \times L}$), играющая роль value-проекции в attention. Слагаемое $f_\theta(z)$ — per-sensor реакционный MLP с pre-norm, по сути — FFN-блок графового трансформера. В корреляционном baseline и в варианте MoE-GA (без Full) $f_\theta \equiv 0$.

4.5 Асимметричная матрица внимания и жёсткий маршрутизатор Гумбеля

Центральный объект работы — матрица $\hat{A}(z)$. Для каждой моды $k = 1, \dots, K$ заведены две независимые линейные проекции [15]

$$W_k^Q, W_k^K \in \mathbb{R}^{L \times d}. \quad (10)$$

Модовая матрица определена как нормированная билинейная форма:

$$A_k(z) = \frac{(zW_k^Q)(zW_k^K)^\top}{\sqrt{d}} \in \mathbb{R}^{C \times C}. \quad (11)$$

Жёсткий маршрутизатор Гумбеля. Маршрутизирующая сеть R_ψ берёт пулированный по датчикам латент $\bar{z} = \frac{1}{C} \sum_i z_i \in \mathbb{R}^L$ и выдаёт логиты $h(z) = R_\psi(\bar{z}) \in \mathbb{R}^K$. Во время

обучения применяется Gumbel–Softmax [4] с убывающей температурой τ_G :

$$\tilde{w}_k = \frac{\exp((h_k + g_k)/\tau_G)}{\sum_{j=1}^K \exp((h_j + g_j)/\tau_G)}, \quad g_k \sim \text{Gumbel}(0, 1), \quad (12)$$

а при малой τ_G один компонент стремится к 1, остальные — к 0. Во время вывода используется жёсткий $\arg \max$:

$$\hat{k}(z) = \arg \max_k h_k(z). \quad (13)$$

Итоговый оператор определяется как:

$$\hat{A}(z) = \text{SN}\left(A_{\hat{k}(z)}(z)\right), \quad (14)$$

где $\text{SN}(\cdot)$ — мягкая нормировка спектрального радиуса [7]: матрица делится на $\max(1, \hat{\sigma}_{\max}/r)$ с целевым $r = 1.5$ и оценкой $\hat{\sigma}_{\max}$ одной итерацией power method.

Ранг оператора и низкоранговое допущение. Поскольку $A_k(z) = (zW_k^Q)(zW_k^K)^\top / \sqrt{d}$ является произведением двух матриц размера $C \times d$, выполнено

$$\text{rank}(A_k(z)) \leq d = L. \quad (15)$$

При жёстком выборе одного эксперта это ограничение действует на каждый отдельный прогноз: $\text{rank}(\hat{A}(z)) \leq L$. Данное ограничение вводится как модельное допущение. Истинные операторы связи физических систем, как правило, эффективно низкоранговы: основная часть дисперсии сосредоточена в нескольких доминирующих направлениях. Для синтетической системы drift-ring истинные операторы T_+ , T_- — циркулянтные матрицы с гауссовым пиком, их спектр убывает, и ранг $L = 3$ покрывает доминирующую структуру. Для ЭЭГ анализ Марченко–Пастура даёт $K_{\text{МР}} = 4$ сигнальных компонент при $C = 64$, что согласуется с гипотезой о низкоранговости. Ограничение $\text{rank} \leq L$ также сокращает число свободных параметров оператора ($2CL$ против C^2 у полноранговой матрицы), что при ограниченном объёме данных предотвращает переобучение и повышает устойчивость оценки. Наконец, низкоранговая матрица допускает компактное представление через доминирующие пары сингулярных векторов, облегчающее содержательную интерпретацию выученных паттернов связности.

Утверждение 3 (Симметричный частный случай). *Если $W_k^Q = W_k^K$ при всех k , то $A_k(z) = (zW_k^Q)(zW_k^Q)^\top / \sqrt{d} \in \mathcal{H}_{\text{sym}}$. Произвольный выбор любого из экспертов остаётся в $\mathcal{H}_{\text{sym}}$, поэтому $\hat{A}(z) \in \mathcal{H}_{\text{sym}}$. Семейство моделей с этим ограничением совпадает с симметричным классом (определение 1).*

Утверждение 4 (Несвязанные проекции покрывают $\mathbb{R}^{C \times C}$). *При $W_k^Q \neq W_k^K$ и $d \geq C$ образ модового отображения $z \mapsto A_k(z)$ при изменении параметров покрывает весь $\mathbb{R}^{C \times C}$.*

Доказательство. Для произвольной $M \in \mathbb{R}^{C \times C}$ и фиксированного z_0 ранга C берём сингулярное разложение $M = U\Sigma V^\top$ и подбираем W_k^Q, W_k^K так, что $z_0 W_k^Q = U\sqrt{d}\Sigma^{1/2}$, $z_0 W_k^K = V\Sigma^{1/2}$. Тогда $A_k(z_0) = M$. $\square$

Замечание 2. Утверждение 4 гарантирует теоретическую выразительность при $d \geq C$. В используемой реализации $d = L < C$; тем самым достигается намеренное низкоранговое приближение. Выбор $d = L$ обоснован в (15) и сопровождающем обсуждении.

Следствие 2 (Иерархия семейств). *Симметричный класс $\mathcal{F}_\Theta^{\text{sym}} \subsetneq \mathcal{F}_\Theta$ — строгое подсемейство предложенной параметризации. Корреляционная модель, ядерные графы и tied-attention лежат в $\mathcal{F}_\Theta^{\text{sym}}$ и наследуют ограничение 1.*

Утверждения 3 и 4 формально замыкают центральный результат работы: предложенная архитектура обобщает симметричные методы, оставаясь способной восстанавливать асимметричные операторы связи.

4.6 Реакционный член

Реакция $f_\theta : \mathbb{R}^{C \times L} \rightarrow \mathbb{R}^{C \times L}$ задана как покомпонентный по датчикам MLP с предварительной нормализацией:

$$f_\theta(z) = W_2 \text{GELU}(W_1 \text{LN}(z)). \quad (16)$$

Веса W_2 инициализированы нулём, что обеспечивает нулевой вклад реакционного члена в начале обучения. Реакционный член компенсирует нелинейные локальные эффекты, не сводимые к парному обмену через граф. Модель без реакционного члена обозначается **MoE-GA**, с реакционным — **MoE-GA Full**.

4.7 Декодер прогноза

Декодер $D : \mathbb{R}^L \rightarrow \mathbb{R}$ есть покомпонентная линейная проекция $D(z_i) = w_D^\top z_i$ с обучаемыми w_D . На каждом шаге rollout z_{k+1} декодируется в скалярную оценку $\hat{s}(t + (k+1)\Delta t)$ по каждому датчику.

Глава 5

Оптимизационная задача

5.1 Реконструкционный лосс автоэнкодера

Обозначим через $\mathcal{T}_{\text{tr}} \subset \{0, \dots, N\}$ множество временных индексов обучающей выборки (хронологический сплит 80/20).

Латентное представление $z(t) = \mu_\phi(\Phi(t))$ обучается не отдельно, а совместно с остальными блоками модели. Декодер автоэнкодера $D_\phi : \mathbb{R}^L \rightarrow \mathbb{R}^m$ восстанавливает по $z_i(t)$ исходный задержечный вектор $\Phi_i(t)$, и качество восстановления входит в общий функционал как реконструкционный член

$$\mathcal{L}_{\text{rec}}(\theta_{\text{enc}}) = \frac{1}{|\mathcal{T}_{\text{tr}}|Cm} \sum_{t \in \mathcal{T}_{\text{tr}}} \|\Phi(t) - D_\phi(z(t))\|_2^2. \quad (17)$$

Реконструкционный член обеспечивает информативность латента: z должен сохранять достаточно информации, чтобы Φ восстанавливался декодером. Энкодер детерминирован — отображение $z(t) = \mu_\phi(\Phi(t))$ применяется одинаково на обучении и на выводе, без сэмплирования и без регуляризации к априорному распределению. Компактность представления обеспечивается явным ограничением размерности $L < m$ (7), а его согласованность с динамикой системы — совместной оптимизацией с прогнозными потерями (раздел 5.2) и регуляризатором фазы (раздел 5.4).

5.2 Прогнозный лосс

Параметры пространственного блока обучаются по двум прогнозным функционалам. Многошаговый горизонтный лосс:

$$\mathcal{L}_{\text{pred}}(\theta) = \frac{1}{|\mathcal{T}_{\text{tr}}|HC} \sum_{t \in \mathcal{T}_{\text{tr}}} \sum_{k=1}^H \|s(t + k\Delta t) - \hat{s}_\theta(t + k\Delta t | t)\|_2^2, \quad (18)$$

где $\hat{s}_\theta(t + k\Delta t \mid t)$ строится итеративным применением (9) к $z(t)$ с последующим декодированием на каждом шаге. Внутриоконный одношаговый лосс:

$$\mathcal{L}_{\text{ind}}(\theta) = \frac{1}{|\mathcal{T}_{\text{tr}}|(W-1)C} \sum_t \sum_{j=0}^{W-2} \|s(t + (j+1)\Delta t) - D(z_{j+1}(t))\|_2^2. \quad (19)$$

Внутриоконный лосс даёт $W - 1$ обучающих точек на каждое окно — существенно больше, чем H точек от горизонтного лосса, и стабилизирует обучение пространственного блока.

5.3 Регуляризатор маршрутизации

Жёсткий маршрутизатор Гумбеля поощряет равномерное использование всех экспертов. Если некоторые эксперты получают мало примеров, они не обучаются. Чтобы предотвратить это, к лоссу добавляется штраф за неравномерность маргинального по батчу распределения режимов

$$\bar{w}(B) = \frac{1}{|B|} \sum_{t \in B} \tilde{w}(z(t)), \quad (20)$$

$$\mathcal{L}_{\text{reg}}(\theta) = \log K - H(\bar{w}(B)) = \text{KL}(\text{Uniform}\{1, \dots, K\} \parallel \bar{w}(B)) \geq 0, \quad (21)$$

где $\tilde{w}$ — мягкое Gumbel-Softmax-распределение из (12), применяемое именно в батче для балансировки нагрузки. Дополнительно финальный слой R_ψ инициализирован нулём, что даёт равномерное стартовое распределение маршрутизации.

5.4 Регуляризатор фазы

Маршрутизатор R_ψ выбирает активного эксперта без явной разметки режимов, опираясь только на латент $z(t)$. Чтобы латент после временного трансформера сохранял информацию, различающую текущий физический режим системы, вводится вспомогательная линейная «фазовая голова», действующая на усреднённый по датчикам латент последнего шага окна $\bar{z}(t) = \frac{1}{C} \sum_{i=1}^C z_i(t) \in \mathbb{R}^L$:

$$\hat{r}_\chi(t) = w_\chi^\top \bar{z}(t) + b_\chi, \quad \chi = (w_\chi, b_\chi) \in \mathbb{R}^L \times \mathbb{R}. \quad (22)$$

Целевая переменная $r(t) \in \{0, 1\}$ — бинарная метка режима системы, доступная на этапе обучения, но не подаваемая модели на вход. Лосс фазы — бинарная кросс-энтропия с логитом $\hat{r}_\chi(t)$:

$$\mathcal{L}_{\text{phase}}(\theta_{\text{temp}}, \chi) = \frac{1}{|\mathcal{T}_{\text{tr}}|} \sum_{t \in \mathcal{T}_{\text{tr}}} \text{BCE}(\sigma(\hat{r}_\chi(t)), r(t)). \quad (23)$$

Минимизация $\mathcal{L}_{\text{phase}}$ заставляет временной трансформер сохранять в $z(t)$ режиморазличающую информацию — именно тот сигнал, на основе которого маршрутизатор R_ψ выбирает активного эксперта. Это ускоряет специализацию экспертов под физические режимы и снижает риск вырождения маршрутизации, особенно на ранних эпохах обучения, когда самой маршрутизирующей сети ещё не хватает сигнала для разделения режимов.

В представленных экспериментах регуляризатор фазы задействован на синтетике drift-ring, где $r(t)$ — знак текущего смещения дрейфующего ядра $v(t)$ (раздел 6), доступный по построению на каждом временном шаге. Архитектура допускает аналогичную метку и для ЭЭГ (например, условие моторного воображения левая/правая рука), однако в проведённых ЭЭГ-экспериментах метка режима не подавалась: фазовая голова не создаётся, $\mathcal{L}_{\text{phase}} \equiv 0$, и функционал (24) для ЭЭГ фактически сводится к четырём слагаемым без $\lambda_4 \mathcal{L}_{\text{phase}}$.

5.5 Совокупная задача оптимизации

Полный функционал

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{pred}} + \lambda_1 \mathcal{L}_{\text{ind}} + \lambda_2 \mathcal{L}_{\text{rec}} + \lambda_3 \mathcal{L}_{\text{reg}} + \lambda_4 \mathcal{L}_{\text{phase}}, \quad (24)$$

объединяет прогнозные слагаемые $\mathcal{L}_{\text{pred}}$, $\mathcal{L}_{\text{ind}}$, обеспечивающие согласованность с наблюдаемой траекторией, реконструкционный член $\mathcal{L}_{\text{rec}}$, обеспечивающий информативность латента, регуляризатор маршрутизации $\mathcal{L}_{\text{reg}}$, предотвращающий коллапс смеси экспертов в один активный режим, и регуляризатор фазы $\mathcal{L}_{\text{phase}}$, удерживающий в латенте режиморазличающую информацию. Задача оптимизации:

$$\theta^* \in \arg \min_{\theta \in \Theta} \mathcal{L}(\theta), \quad (25)$$

$\theta = (\theta_{\text{enc}}, \theta_{\text{temp}}, \theta_{\text{op}}, \alpha_0, \psi, \chi, \theta_{\text{dec}})$. Решается AdamW с косинусным расписанием learning rate; все блоки обучаются совместно.

Совокупный функционал (24) устроен так, что снижение размерности и обучение оператора связности происходят согласованно. Прогнозный член $\mathcal{L}_{\text{pred}}$ вынуждает $\hat{A}_\theta(z)$ точно описывать направленную динамику; реконструкционный член $\mathcal{L}_{\text{rec}}$ совместно с ограничением размерности $L < m$ обеспечивает компактное латентное представление размерности $CL \ll Ct$; регуляризатор фазы $\mathcal{L}_{\text{phase}}$ удерживает в этом представлении информацию о текущем режиме системы, облегчая работу маршрутизатора (на синтетике, раздел 5.4); регуляризатор $\mathcal{L}_{\text{reg}}$ предотвращает вырождение маршрутизатора в один активный режим, поддерживая равномерную загрузку экспертов.

Корреляционный baseline получается изоляцией θ_{op} к симметричному подсемейству: вместо смеси экспертов с W_k^Q, W_k^K используется заранее посчитанная нормированная корреляция $\hat{\Sigma}$, и обучаемой остаётся только её скалярная амплитуда γ .

Глава 6

Вычислительный эксперимент

6.1 Сценарии

Эксперимент проведён на двух датасетах. Первый — контролируемая синтетическая система с заранее известным истинным оператором $A(u)$, позволяющая прямо сравнивать восстановленную модель с истиной. Второй — реальные ЭЭГ-данные моторного воображения из открытой коллекции PhysioNet eegbci [11], проверяющие применимость подхода вне синтетики.

6.2 Синтетический датасет: кольцо с дрейфующим ядром

Распределённая система задана на одномерном кольце из $C = 16$ датчиков. Эволюция наблюдений определяется циркулянтным оператором, первая строка которого пропорциональна гауссиане со смещением; центр смещения $v(t)$ переключается каждые 500 шагов между двумя значениями $+v_0$ и $-v_0$. Это даёт бинарное чередование режимов переноса вправо и влево. Истинный оператор связи в каждом режиме обладает асимметрией $\|A - A^\top\|_F / \|A\|_F \approx 1,41$, а усреднённый по двум режимам оператор симметричен. К наблюдениям добавляется аддитивный гауссовский шум $\sigma = 0,3$, ряд стандартизуется поканально. Длина траектории $T = 3000$.

6.3 Реальный датасет: ЭЭГ моторного воображения

Используется один испытуемый из PhysioNet eegbci [11], эксперименты 4, 8, 12 (motor imagery левой и правой руки), $C = 64$ электрода, частота дискретизации 160 Гц, сегмент длиной $T = 30000$ отсчётов после полосовой фильтрации 1–40 Гц и стандартизации поканально. Для ЭЭГ гиперпараметры определяются автоматически по (8): $\tau = 9$, $m = 5$, $L = \text{round}(5 \times 2/3) = 3$ (7); $K_{\text{MP}} = 4$, $K_{\text{bands}} = 3$, итого $K = 4$. На синтетике: $m \in \{4, 5\}$ (авто по FNN), $L = 3$, $K = 6$ (вручную).

6.4 Сравнимые модели

Все три модели разделяют общий автоэнкодер, временной трансформер, правило rollout, декодер и весовые коэффициенты лосса; на синтетике дополнительно — фазовую голову (раздел 5.4). Различие сосредоточено в пространственном блоке. Модель **Корреляция** использует $\hat{A}(z) = \gamma \hat{\Sigma}$, где $\hat{\Sigma}$ — предвычисленная корреляция Пирсона наблюдений тренировочной части, нормированная на свой спектральный радиус; это симметричный baseline, принадлежащий классу из определения 1. Модель **MoE-GA** строит $\hat{A}(z)$ из смеси (14) с несвязанными проекциями W_k^Q, W_k^K и жёстким маршрутизатором Гумбеля; реакционный член $f_\theta \equiv 0$. Модель **MoE-GA Full** дополняет то же $\hat{A}(z)$ реакционным MLP $f_\theta(z)$.

6.5 Параметры обучения

Длина окна $W = 32$, отбрасываемый window 8, горизонт $H = 4$ на синтетике и $H = 8$ на ЭЭГ. Размерность энкодера $d_{\text{model}} = 32$. Размерность латента $L = \text{round}(m \times 2/3)$: на синтетике $L = 3$ (из $m = 5$), на ЭЭГ $L = 3$ (из $m = 5, \tau = 9$). Число компонент смеси K : на синтетике $K = 6$ (задано вручную, перекрывает два режима с запасом); на ЭЭГ $K = 4$ (автоматически по (8)). Температура Гумбеля убывает линейно от $\tau_G = 1,0$ до $\tau_G = 0,2$ за эпохи обучения. Скрытая размерность голов $d = L$ (совпадает с латентной размерностью, поэтому $\text{rank}(\hat{A}) \leq L$ по (15)). Целевой спектральный радиус $r = 1,5$. Коэффициенты лосса: $\lambda_1 = 1, \lambda_2 = 0,5, \lambda_3 = 0,05, \lambda_4 = 0,3$ (используется только на синтетике, раздел 5.4). Оптимизатор AdamW, learning rate $3 \cdot 10^{-3}$, косинусное расписание, 50 эпох, batch size 64 на синтетике и 128 на ЭЭГ. Сплит 80/20 по времени.

6.6 Метрики

Качество прогноза измеряется среднеквадратичной ошибкой по горизонту (18), усреднённой по тестовой выборке и каналам (MSE). Для синтетической задачи, где истинный оператор A известен, дополнительно вычисляются: мера асимметрии восстановленного оператора $A_{\text{asym}} = \|\hat{A} - \hat{A}^\top\|_F / \|\hat{A}\|_F$ и линейная корреляция $\rho(\hat{A}_\pm, A_\pm)$ между восстановленным и истинным операторами для каждого из двух режимов.

6.7 Результаты на синтетике

Сводные числа на отложенной выборке приведены в табл. 1. Среднее по горизонту MSE вычислено по 5 сдам ($\pm \text{std}$).

Корреляционный baseline даёт асимметрию ≈ 0 по построению и одинаковую корреляцию с обоими истинными режимами — в точном соответствии со следствием 1:

Таблица 1. Синтетика (кольцо $C = 16$, $T = 3000$, бинарные режимы, 5 прогонов). MSE — среднее по горизонту на тестовой выборке; $A_{\text{asym}} = \|\hat{A} - \hat{A}^\top\|_F / \|\hat{A}\|_F$; истинная асимметрия оператора $\approx 1,41$.

Модель	MSE	A_{asym}	Улучш. vs корр.
Корреляция	$0,229 \pm 0,035$	≈ 0	—
MoE-GA	$0,211 \pm 0,023$	0,467	7,9 %
MoE-GA Full	$0,204 \pm 0,024$	0,255	11,1 %




Рис. 2. Синтетика: кривые MSE на валидации по эпохам (mean $\pm$ std по 5 сидам).

модель неспособна различать направления переноса. MoE-GA восстанавливает асимметрию 0,467 — заметно выше нуля, хотя и ниже истинной 1,41; это означает, что модель различает направления переноса, а MSE снижается на 7,9 %. MoE-GA Full достигает наилучшей ошибки прогноза (0,204 против 0,229 у корреляции, выигрыш 11,1 %); асимметрия восстановленного оператора при этом ниже, чем у MoE-GA (0,255 против 0,467), поскольку реакционный член перехватывает часть направленной структуры, перенося её из парного графового обмена в локальный нелинейный шаг. По горизонту прогноза (рис. 4) обе модели MoE-GA устойчиво опережают корреляцию на всех шагах $h = 1, \dots, 4$.

Иерархия согласована с теорией: переход от симметричного класса $\mathcal{F}_{\Theta}^{\text{sym}}$ к полному $\mathcal{F}_{\Theta}$ устраняет неустранимую границу из утверждения 2 и снижает практический MSE.




Рис. 3. Синтетика: итоговые MSE трёх моделей (mean $\pm$ std по 5 сидам).

6.8 Результаты на ЭЭГ

Сводные числа приведены в табл. 2. Истинный оператор $A(u)$ для ЭЭГ недоступен; асимметрия $\hat{A}$ приведена только как структурная характеристика выученной модели. Горизонт прогноза $H = 8$ шагов.

Таблица 2. ЭЭГ motor imagery, $C = 64$, $T = 30000$ отсчётов, 3 прогона.

Модель	MSE	A_{asym}	Улучш. vs корр.
Корреляция	$0,472 \pm 0,007$	≈ 0	—
MoE-GA	$0,450 \pm 0,006$	0,016	4,7 %
MoE-GA Full	$0,440 \pm 0,007$	0,085	6,8 %

MoE-GA снижает MSE на 4,7 % относительно корреляции (0,450 против 0,472). Выигрыш скромнее, чем на синтетике: в ЭЭГ моторного воображения направленная составляющая сигнала выражена слабее, и основная часть прогностически значимой информации сосредоточена в симметричной части. MoE-GA Full достигает наилучшей ошибки (0,440, выигрыш 6,8 %): реакционный MLP захватывает нелинейные местные эффекты, слабо отражаемые в недиагональных элементах оператора связи, и, в отличие от синтетики, обеспечивает улучшение на всём горизонте. По горизонту прогноза (рис. 9) MoE-GA Full опережает остальные варианты на длинных шагах ($h \geq 3$), тогда как на первом шаге разрыв между моделями минимален. Асимметрия восстановленного оператора (0,016 у MoE-GA, 0,085 у MoE-GA Full) невелика относительно синтетики, что согласуется с синхронизационной природой альфа/бета-ритмов ЭЭГ и преимущественно симметричным характером функциональной связности.




Рис. 4. Синтетика: MSE как функция шага горизонта прогноза $h = 1, \dots, 4$.

6.9 Анализ восстановленных матриц связности

6.9.1 Синтетика: drift-ring

На синтетической задаче известны истинные операторы T_+ и T_- , что позволяет прямо сравнить восстановленные матрицы с эталоном. Мера асимметрии истинного оператора: $a(T_{\pm}) = \|T_{\pm} - T_{\pm}^T\|_F / \|T_{\pm}\|_F \approx 1,41$, что отражает циркулянтный сдвиг в одном направлении.

Ключевые количественные характеристики (seed 0):

- **Correlation:** $a = 0,000$ — симметрична по построению; корреляция с эталоном одинакова для обоих режимов ($\rho(\hat{A}_+, T_+) = \rho(\hat{A}_+, T_-) = 0,33$), что подтверждает невозможность различить направление переноса симметричной моделью.
- **MoE-GA:** $a = 1,58$ — захватывает высокую асимметрию, близкую к истинной (1,41). Корреляция с «своим» режимом выше, чем с противоположным ($\rho(\hat{A}_+, T_+) = 0,51$, $\rho(\hat{A}_-, T_-) = 0,37$). Маршрутизатор преимущественно активирует моды 4 и 5 (веса $\bar{w}_4 = 0,48$, $\bar{w}_5 = 0,42$), что соответствует переключению между двумя доминирующими паттернами переноса.
- **MoE-GA Full:** $a = 0,09$ — реакционный член f_{θ} берёт на себя часть направленной динамики, снижая требования к асимметрии диффузионного оператора. При этом корреляция $\rho(\hat{A}_+, T_+) = 0,45$ сохраняется положительной, а $\rho(\hat{A}_-, T_-) = -0,43$ — отрицательной, что означает корректное обнаружение инверсии направления переноса при смене режима. Веса мод более равномерны ($\bar{w} \approx [0,28, 0,31, 0,20, 0,01, 0,13, 0,07]$), отражая совместную параметризацию диффузии и реакции.

6.9.2 ЭЭГ

На реальных данных истинный оператор $A(u)$ недоступен, поэтому анализ носит структурный характер.

На матрицах ЭЭГ видна блочная структура: выделяются кластеры электродов, соответствующие моторной коре (центро-теменные каналы Cz, C3, C4), фронтальным и окципитальным группам. Это согласуется с нейрофизиологическими ожиданиями для задачи motor imagery.

Маршрутизатор MoE-GA Full разделяет $K = 4$ режима с практически равномерным использованием ($\bar{w} \approx [0,31, 0,38, 0,14, 0,17]$), что указывает на эффективное использование всех экспертов и согласуется с критерием $K_{MP} = 4$ (четыре сигнальных собственных значения по Марченко–Пастуру). Каждый эксперт специализируется на определённом пространственном паттерне: эксперт 2 с наибольшим весом ($\bar{w} = 0,38$) отражает доминирующую низкочастотную компоненту (δ -ритм), остальные кодируют более локализованные связи.

6.10 Обсуждение результатов

Совокупность результатов согласуется со следствием 1: симметричная корреляция тождественно равна нулю по мере асимметрии и не способна различать режимы переноса, тогда как предложенная архитектура восстанавливает значимую антисимметричную составляющую. На синтетической задаче с заведомо асимметричным оператором MSE снижается на 11,1 % у MoE-GA Full и на 7,9 % у MoE-GA, что согласовано с теоретически предсказанной неустранимой ошибкой симметричного класса. На ЭЭГ прирост составляет 6,8 % и 4,7 % соответственно. Выход за пределы симметричного класса, сохраняя низкоранговую структуру оператора, обеспечивает измеримый прогнозный выигрыш при физически корректном описании направленной связности.




Рис. 5. Синтетика: компоненты функционала потерь по эпохам обучения.




Рис. 6. Синтетика: разрыв между train и val MSE по эпохам. Малый разрыв у MoE-GA и MoE-GA Full указывает на хорошую обобщающую способность при $T = 3000$.




Рис. 7. ЭЭГ: кривые MSE на валидации по эпохам (mean $\pm$ std по 3 сидам).




Рис. 8. ЭЭГ: итоговые MSE трёх моделей (mean $\pm$ std по 3 сидам).




Рис. 9. ЭЭГ: MSE как функция шага горизонта прогноза $h = 1, \dots, 8$.




Рис. 10. ЭЭГ: компоненты функционала потерь по эпохам обучения. Phase BCE тождественно равна нулю: метка режима в ЭЭГ-экспериментах не подавалась (раздел 5.4).




Рис. 11. ЭЭГ: разрыв между train и val MSE по эпохам. Стабильный разрыв без расхождения свидетельствует об устойчивости обучения на $T = 30000$.




Рис. 12. Drift-ring: средние матрицы $\hat{A}$ по двум режимам ($v > 0$ и $v < 0$) для трёх моделей и истинных операторов T_+ , T_- .




Рис. 13. Drift-ring: разности $\hat{A}_+ - \hat{A}_-$ (чувствительность к смене режима). У Corr разность близка к нулю; у MoE-GA — выражена.




Рис. 14. Drift-ring: матрицы отдельных экспертов MoE-GA Full ($K = 6$). Моды 1–2 кодируют перенос вправо, моды 3–4 — влево; средние веса маршрутизатора указаны над каждой матрицей.




Рис. 15. ЭЭГ: средние матрицы $\hat{A}$ по всем сэмплам ($C = 64$): Corr (слева), MoE-GA (центр), MoE-GA Full (справа). Мера асимметрии: 0, 0,023, 0,040 соответственно. Видна блочная структура, соответствующая анатомическим группам электродов.




Рис. 16. ЭЭГ: матрицы экспертов MoE-GA ($K = 4$). Средние веса: $\bar{w} \approx [0,28, 0,26, 0,27, 0,19]$. Равномерное использование всех четырёх экспертов указывает на отсутствие монополизации и покрытие разных паттернов связности.




Рис. 17. ЭЭГ: матрицы экспертов MoE-GA Full ($K = 4$). Средние веса: $\bar{w} \approx [0,31, 0,38, 0,14, 0,17]$. Эксперт 2 доминирует — кодирует низкочастотную (δ) компоненту; остальные специализированы на более локальных связях.

Глава 7

Заключение

В работе сформулирован и подтверждён тезис о том, что асимметричная матрица внимания, построенная на основе геометрии фазового пространства, лучше подходит для предсказания и восстановления скрытых зависимостей, чем классическая симметричная корреляционная матрица. Показано принципиальное ограничение симметричных моделей: их образ лежит в подпространстве $\mathcal{H}_{\text{sym}}$, и любой симметричный аппроксиматор имеет неустранимую ошибку $\|A_{\text{asym}}\|_F$ относительно истинного оператора связи.

Предложена архитектура **MoE-GA** на базе смеси экспертов с multi-head attention с несвязанными проекциями запросов и ключей и жёстким маршрутизатором Гумбеля ($k = 1$). Жёсткий Gumbel-выбор гарантирует, что каждый образец обрабатывается ровно одним экспертом, устраняя паразитный градиентный сигнал от «спящих» ядер и упрощая интерпретацию. Размерность латента $L = \text{round}(m \times 2/3)$ обеспечивает сжатие задержечных координат Такенса примерно на треть. Жёсткая маршрутизация ($k = 1$) влечёт $\text{rank}(\hat{A}) \leq L$ на каждый прогноз — осознанное низкоранговое допущение, обоснованное эффективно низкоранговой структурой физических операторов, регуляризирующим эффектом при малом T и интерпретируемостью. Число мод K на ЭЭГ выбирается автоматически из данных по трём критериям: порог Марченко–Пастура, число частотных полос и покрытие ранга; на синтетике K задаётся вручную исходя из числа физических режимов.

Класс MoE-GA снимает симметричное ограничение и покрывает всё пространство $\mathbb{R}^{C \times C}$. Симметричные модели — корреляционные, ядерно-графовые, tied-attention — являются строгим частным случаем предложенного класса при равенстве проекций. Это позволяет одной архитектурой обобщить существующие подходы и одновременно дать модели возможность выходить за пределы симметричной части.

Архитектура замыкается на двух уровнях редукции. На уровне состояния используется автоэнкодер над задержечными координатами Такенса [13, 10]; реконструкционный лосс совместно с ограничением размерности $L < m$ и регуляризатором фазы даёт компактное низкоразмерное представление, согласованное с динамикой системы. На уровне оператора пространственная динамика реализована как residual graph-attention блок со смесью асимметричных матриц сходств [15, 16] и опциональным реакционным

MLP. Альтернативные подходы к data-driven редукции для управления — Коорман-операторный анализ [1], динамическое модовое разложение с управлением [8], LPV-планирование [9] — остаются естественными downstream-приложениями полученной модели.

Эмпирическая проверка на синтетике с заведомо асимметричным оператором подтверждает достигнутые теоретические результаты: MoE-GA Full снижает MSE прогноза на 11,1 % относительно симметричного baseline и восстанавливает направленность переноса ($A_{\text{asym}} = 0,255$ против 0 у корреляции). MoE-GA без реакционного члена даёт выигрыш 7,9 % при более высокой асимметрии оператора (0,467). На реальных данных ЭЭГ моторного воображения наблюдается аналогичный, хотя и более скромный, прирост: 6,8 % у MoE-GA Full и 4,7 % у MoE-GA.

Литература

- [1] S. L. Brunton, B. W. Brunton, J. L. Proctor, and J. N. Kutz. Koopman invariant subspaces and finite linear representations of nonlinear dynamical systems for control. *PLOS ONE*, 11(2):e0150171, 2016.
- [2] W. Fedus, B. Zoph, and N. Shazeer. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity. *Journal of Machine Learning Research*, 23(120):1–39, 2022. Preprint arXiv:2101.03961, 2021.
- [3] C. W. J. Granger. Investigating causal relations by econometric models and cross-spectral methods. *Econometrica*, 37(3):424–438, 1969.
- [4] E. Jang, S. Gu, and B. Poole. Categorical reparameterization with gumbel-softmax. In *International Conference on Learning Representations*, 2017.
- [5] D. P. Kingma and M. Welling. Auto-encoding variational bayes. In *International Conference on Learning Representations*, 2014.
- [6] Y. Li, R. Yu, C. Shahabi, and Y. Liu. Diffusion convolutional recurrent neural network: Data-driven traffic forecasting. In *International Conference on Learning Representations*, 2018.
- [7] T. Miyato, T. Kataoka, M. Koyama, and Y. Yoshida. Spectral normalization for generative adversarial networks. In *International Conference on Learning Representations*, 2018.
- [8] J. L. Proctor, S. L. Brunton, and J. N. Kutz. Dynamic mode decomposition with control. *SIAM Journal on Applied Dynamical Systems*, 15(1):142–161, 2016.
- [9] W. J. Rugh and J. S. Shamma. Research on gain scheduling. *Automatica*, 36(10):1401–1425, 2000. Ключевой обзор LPV/gain-scheduling методов.
- [10] T. Sauer, J. A. Yorke, and M. Casdagli. Embedology. *Journal of Statistical Physics*, 65(3–4):579–616, 1991.
- [11] G. Schalk, D. J. McFarland, T. Hinterberger, N. Birbaumer, and J. R. Wolpaw. BCI2000: A general-purpose brain-computer interface system. *IEEE Transactions on Biomedical Engineering*, 51(6):1034–1043, 2004.

-
- [12] G. Sugihara, R. May, H. Ye, C. H. Hsieh, E. Deyle, M. Fogarty, and S. Munch. Detecting causality in complex ecosystems. *Science*, 338(6106):496–500, 2012.
 - [13] F. Takens. Detecting strange attractors in turbulence. In *Dynamical Systems and Turbulence, Warwick 1980*, volume 898 of *Lecture Notes in Mathematics*, pages 366–381. Springer, 1981.
 - [14] R. Temam. *Infinite-Dimensional Dynamical Systems in Mechanics and Physics*. Springer, 2nd edition, 1997.
 - [15] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
 - [16] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, and Y. Bengio. Graph attention networks. In *International Conference on Learning Representations*, 2018.